

VYSOKÁ ŠKOLA EKONOMICKÁ V PRAZE  
FAKULTA INFORMATIKY A STATISTIKY



# STATISTIKA PRO INFORMATIKY

VZORCE PRO 4ST204

# Obsah

|          |                                                               |           |
|----------|---------------------------------------------------------------|-----------|
| <b>1</b> | <b>Popisná Statistika</b>                                     | <b>4</b>  |
| 1.1      | Četnosti . . . . .                                            | 4         |
| 1.1.1    | Absolutní četnost . . . . .                                   | 4         |
| 1.1.2    | Součet absolutních četností . . . . .                         | 4         |
| 1.1.3    | Relativní Četnost . . . . .                                   | 4         |
| 1.1.4    | Součet relativních četností . . . . .                         | 4         |
| 1.1.5    | Kumulativní absolutní četnost . . . . .                       | 5         |
| 1.1.6    | Kumulativní relativní četnost . . . . .                       | 5         |
| 1.2      | Charakteristiky polohy . . . . .                              | 6         |
| 1.2.1    | Aritmetický průměr . . . . .                                  | 6         |
| 1.2.2    | Vážený aritmetický průměr (z četnostní tabulky) . . . . .     | 6         |
| 1.2.3    | Aritmetický průměr pomocí relativních četností . . . . .      | 7         |
| 1.2.4    | Harmonický průměr . . . . .                                   | 8         |
| 1.2.5    | Geometrický průměr . . . . .                                  | 8         |
| 1.2.6    | Vztah mezi průměry . . . . .                                  | 9         |
| 1.2.7    | Medián . . . . .                                              | 9         |
| 1.2.8    | Kvantily a kvartily . . . . .                                 | 10        |
| 1.2.9    | Interkvartilové rozpětí (IQR) . . . . .                       | 11        |
| 1.2.10   | Modus . . . . .                                               | 12        |
| 1.3      | Charakteristiky variability . . . . .                         | 12        |
| 1.3.1    | Variační rozpětí . . . . .                                    | 12        |
| 1.3.2    | Rozptyl statistického souboru . . . . .                       | 13        |
| 1.3.3    | Výběrový rozptyl . . . . .                                    | 14        |
| 1.3.4    | Vážený rozptyl . . . . .                                      | 14        |
| 1.3.5    | Směrodatná odchylka statistického souboru . . . . .           | 15        |
| 1.3.6    | Výběrová směrodatná odchylka . . . . .                        | 16        |
| 1.3.7    | Variační koeficient . . . . .                                 | 16        |
| 1.3.8    | Střední absolutní odchylka (MAD) . . . . .                    | 17        |
| 1.3.9    | Detekce odlehlých hodnot – Tukeyovy meze . . . . .            | 18        |
| <b>2</b> | <b>Teorie pravděpodobnosti</b>                                | <b>19</b> |
| 2.1      | Počet pravděpodobnosti . . . . .                              | 19        |
| 2.1.1    | Klasická definice pravděpodobnosti . . . . .                  | 19        |
| 2.1.2    | Pravděpodobnost komplementárního jevu . . . . .               | 19        |
| 2.1.3    | Horní odhad pravděpodobnosti průniku . . . . .                | 19        |
| 2.1.4    | Průnik nezávislých jevů . . . . .                             | 19        |
| 2.1.5    | Sjednocení dvou jevů . . . . .                                | 20        |
| 2.1.6    | Sjednocení neslučitelných jevů . . . . .                      | 20        |
| 2.1.7    | Podmíněná pravděpodobnost . . . . .                           | 20        |
| 2.1.8    | Věta o úplné pravděpodobnosti . . . . .                       | 20        |
| 2.2      | Náhodné veličiny . . . . .                                    | 21        |
| 2.2.1    | Pravděpodobnostní funkce diskrétní náhodné veličiny . . . . . | 21        |
| 2.2.2    | Distribuční funkce diskrétní náhodné veličiny . . . . .       | 21        |
| 2.2.3    | Pravděpodobnost intervalu . . . . .                           | 21        |
| 2.2.4    | Střední hodnota diskrétní náhodné veličiny . . . . .          | 22        |
| 2.2.5    | Rozptyl diskrétní náhodné veličiny . . . . .                  | 22        |
| 2.2.6    | Hustota pravděpodobnosti spojitě náhodné veličiny . . . . .   | 22        |
| 2.2.7    | Normalizační podmínka hustoty pravděpodobnosti . . . . .      | 23        |
| 2.2.8    | Distribuční funkce spojitě náhodné veličiny . . . . .         | 23        |
| 2.2.9    | Pravděpodobnost intervalu spojitě náhodné veličiny . . . . .  | 23        |

|          |                                                              |           |
|----------|--------------------------------------------------------------|-----------|
| 2.2.10   | Střední hodnota spojitě náhodné veličiny . . . . .           | 24        |
| 2.2.11   | Rozptyl spojitě náhodné veličiny . . . . .                   | 24        |
| 2.2.12   | Směrodatná odchylka náhodné veličiny . . . . .               | 24        |
| 2.3      | Vlastnosti střední hodnoty a rozptylu . . . . .              | 25        |
| 2.3.1    | Vlastnosti střední hodnoty $E(X)$ . . . . .                  | 25        |
| 2.3.2    | Vlastnosti rozptylu $D(X)$ . . . . .                         | 25        |
| <b>3</b> | <b>Kombinatorika a Metriky</b>                               | <b>26</b> |
| 3.1      | Kombinatorika . . . . .                                      | 26        |
| 3.2      | $L^p$ Normy (Vzdálenosti a penalizace) . . . . .             | 26        |
| <b>4</b> | <b>Pravděpodobnostní rozdělení</b>                           | <b>27</b> |
| 4.1      | Diskrétní rozdělení . . . . .                                | 27        |
| 4.1.1    | Binomické rozdělení $\text{Bin}(n, p)$ . . . . .             | 27        |
| 4.1.2    | Poissonovo rozdělení $\text{Pois}(\lambda)$ . . . . .        | 27        |
| 4.1.3    | Hypergeometrické rozdělení $\text{Hyper}(N, K, n)$ . . . . . | 28        |
| 4.2      | Spojité rozdělení . . . . .                                  | 29        |
| 4.2.1    | Normální rozdělení $N(\mu, \sigma^2)$ . . . . .              | 29        |
| 4.2.2    | Rovnoměrné rozdělení $U(a, b)$ . . . . .                     | 30        |
| 4.2.3    | Exponenciální rozdělení $\text{Exp}(\lambda)$ . . . . .      | 31        |
| 4.3      | Odvozená rozdělení . . . . .                                 | 32        |
| 4.3.1    | Studentovo t-rozdělení $t(\nu)$ . . . . .                    | 32        |
| 4.3.2    | Chí-kvadrát rozdělení $\chi^2(k)$ . . . . .                  | 33        |
| 4.3.3    | F-rozdělení $F(k_1, k_2)$ . . . . .                          | 33        |
| <b>5</b> | <b>Testování hypotéz</b>                                     | <b>35</b> |
| 5.1      | Chyby testování hypotéz . . . . .                            | 35        |
| 5.2      | Bodový odhad . . . . .                                       | 35        |
| 5.3      | Intervaly spolehlivosti a velikost výběru . . . . .          | 35        |
| 5.3.1    | Interval pro průměr ( $\mu$ ) . . . . .                      | 35        |
| 5.3.2    | Interval pro podíl ( $\pi$ ) . . . . .                       | 36        |
| 5.3.3    | Potřebná velikost výběru ( $n$ ) . . . . .                   | 37        |
| 5.4      | Jednovýběrový t-test (střední hodnota) . . . . .             | 38        |
| 5.5      | Dvouvýběrový t-test (Welchův) . . . . .                      | 39        |
| 5.6      | Párový t-test . . . . .                                      | 39        |
| 5.7      | Test proporce (Z-test) . . . . .                             | 40        |
| 5.8      | Jednocestná analýza rozptylu (ANOVA) . . . . .               | 41        |
| 5.9      | Chí-kvadrát test dobré shody . . . . .                       | 41        |
| 5.10     | Chí-kvadrát test nezávislosti . . . . .                      | 42        |
| 5.11     | Stupně volnosti – přehled . . . . .                          | 43        |
| <b>6</b> | <b>Analýza závislosti</b>                                    | <b>44</b> |
| 6.1      | Korelační analýza . . . . .                                  | 44        |
| 6.1.1    | Pearsonův korelační koeficient . . . . .                     | 44        |
| 6.1.2    | Spearmanův korelační koeficient . . . . .                    | 44        |
| 6.2      | Jednoduchá lineární regrese . . . . .                        | 45        |
| 6.2.1    | Odhad koeficientů (MNČ) . . . . .                            | 45        |
| 6.2.2    | Součty čtverců a koeficient determinace $R^2$ . . . . .      | 45        |
| 6.2.3    | t-test a F-test platnosti modelu . . . . .                   | 46        |
| 6.2.4    | Predikce . . . . .                                           | 47        |

|           |                                                       |           |
|-----------|-------------------------------------------------------|-----------|
| <b>7</b>  | <b>Časové řady</b>                                    | <b>48</b> |
| 7.1       | Základní charakteristiky . . . . .                    | 48        |
| 7.1.1     | Absolutní přírůstky a tempa růstu . . . . .           | 48        |
| 7.1.2     | Chronologický průměr . . . . .                        | 48        |
| 7.2       | Řetězové a bazické indexy . . . . .                   | 49        |
| 7.3       | Klouzavé průměry . . . . .                            | 49        |
| 7.3.1     | Prostý klouzavý průměr (liché $m$ ) . . . . .         | 49        |
| 7.3.2     | Centrovaný klouzavý průměr (sudé $m$ ) . . . . .      | 50        |
| 7.4       | Trend a sezónnost – regresní přístup . . . . .        | 50        |
| 7.4.1     | Dummy proměnné a model . . . . .                      | 50        |
| 7.4.2     | Dekompozice časové řady . . . . .                     | 51        |
| 7.4.3     | Predikce na budoucí období . . . . .                  | 52        |
| 7.5       | Nelineární trendy časových řad . . . . .              | 52        |
| 7.5.1     | Kvadratický (parabolický) trend . . . . .             | 52        |
| 7.5.2     | Exponenciální trend . . . . .                         | 53        |
| <b>8</b>  | <b>Indexní analýza</b>                                | <b>55</b> |
| 8.1       | Složené individuální indexy . . . . .                 | 55        |
| 8.2       | Souhrnné (Laspeyresovy a Paascheho) indexy . . . . .  | 56        |
| 8.3       | Fisherův (ideální) index . . . . .                    | 57        |
| <b>9</b>  | <b>Příloha: Utility funkce v Pythonu</b>              | <b>58</b> |
| 9.1       | Užitečné knihovny a základy . . . . .                 | 58        |
| 9.2       | Práce s poli (Standardní Python) . . . . .            | 58        |
| 9.3       | Základní Python (Built-in & Math) . . . . .           | 59        |
| 9.4       | Statistika a Matice (Knihovna NumPy a jiné) . . . . . | 60        |
| 9.5       | Pandas: Analýza dat . . . . .                         | 62        |
| 9.6       | Matplotlib a Seaborn: Vizualizace . . . . .           | 64        |
| <b>10</b> | <b>Příloha: Utility funkce v R</b>                    | <b>65</b> |
| 10.1      | Užitečné balíčky . . . . .                            | 65        |
| 10.2      | Vektory a datové typy . . . . .                       | 65        |
| 10.3      | Práce s daty v R . . . . .                            | 66        |

# 1 Popisná Statistika

## 1.1 Četnosti

### 1.1.1 Absolutní četnost

Absolutní četnost  $i$ -té hodnoty je počet výskytů dané hodnoty ve výběru.

$$n_i$$

kde

- $n_i$  je počet výskytů  $i$ -té hodnoty ve výběru.

### 1.1.2 Součet absolutních četností

Součet absolutních četností všech hodnot (nebo tříd) ve výběru se rovná celkovému počtu pozorování.

$$\sum_{i=1}^k n_i = n$$

kde

- $\sum$  je sumační znak (značí sčítání),
- $i$  je index hodnoty nebo třídy,
- $k$  je počet různých hodnot nebo tříd,
- $n_i$  je absolutní četnost  $i$ -té hodnoty (nebo třídy),
- $n$  je celkový počet pozorování.

### 1.1.3 Relativní Četnost

Relativní četnost  $i$ -té hodnoty ve výběru je definována jako podíl absolutní četnosti dané hodnoty a celkového počtu pozorování,

$$p_i = \frac{n_i}{n}$$

kde

- $p_i$  je relativní četnost  $i$ -té hodnoty,
- $n_i$  je absolutní četnost  $i$ -té hodnoty (kolikrát se hodnota vyskytla),
- $n$  je celkový počet pozorování v souboru.

### 1.1.4 Součet relativních četností

Součet relativních četností všech hodnot (nebo tříd) ve výběru je roven jedné.

$$\sum_{i=1}^k p_i = 1$$

kde

- $\sum$  je sumační znak (značí sčítání),
- $i$  je index hodnoty nebo třídy,
- $k$  je počet různých hodnot nebo tříd,
- $p_i$  je relativní četnost  $i$ -té hodnoty (nebo třídy).

### 1.1.5 Kumulativní absolutní četnost

Kumulativní absolutní četnost  $i$ -té hodnoty je součet absolutních četností všech hodnot až do  $i$ -té (včetně).

$$N_i = \sum_{j=1}^i n_j$$

kde

- $N_i$  je kumulativní absolutní četnost  $i$ -té hodnoty,
- $n_j$  je absolutní četnost  $j$ -té hodnoty,
- $i$  je index hodnoty nebo třídy.

#### Implementace v R

| Funkce                  | Příklad použití                                        | Vysvětlení                                             |
|-------------------------|--------------------------------------------------------|--------------------------------------------------------|
| <code>cumsum(ni)</code> | <pre>ni &lt;- c(5, 10, 8, 7) Ni &lt;- cumsum(ni)</pre> | Vrací kumulativní součty vektoru absolutních četností. |

#### Implementace v Python

| Funkce                     | Příklad použití                                                               | Vysvětlení                                          |
|----------------------------|-------------------------------------------------------------------------------|-----------------------------------------------------|
| <code>np.cumsum(ni)</code> | <pre>import numpy as np ni = np.array([5, 10, 8, 7]) Ni = np.cumsum(ni)</pre> | Vrací kumulativní součty pole absolutních četností. |

### 1.1.6 Kumulativní relativní četnost

Kumulativní relativní četnost  $i$ -té hodnoty je součet relativních četností všech hodnot až do  $i$ -té (včetně). Odpovídá hodnotám empirické distribuční funkce; platí  $P_k = 1$ .

$$P_i = \sum_{j=1}^i p_j$$

kde

- $P_i$  je kumulativní relativní četnost  $i$ -té hodnoty,
- $p_j$  je relativní četnost  $j$ -té hodnoty,
- $i$  je index hodnoty nebo třídy.

#### Implementace v R

| Funkce                  | Příklad použití                                                              | Vysvětlení                            |
|-------------------------|------------------------------------------------------------------------------|---------------------------------------|
| <code>cumsum(pi)</code> | <pre>ni &lt;- c(5, 10, 8, 7) pi &lt;- ni / sum(ni) Pi &lt;- cumsum(pi)</pre> | Vrací kumulativní relativní četnosti. |

## Implementace v Python

| Funkce                     | Příklad použití                                                                                  | Vysvětlení                            |
|----------------------------|--------------------------------------------------------------------------------------------------|---------------------------------------|
| <code>np.cumsum(pi)</code> | <pre>import numpy as np ni = np.array([5, 10, 8, 7]) pi = ni / ni.sum() Pi = np.cumsum(pi)</pre> | Vrací kumulativní relativní četnosti. |

## 1.2 Charakteristiky polohy

### 1.2.1 Aritmetický průměr

Aritmetický průměr (výběrový průměr) je definován jako součet všech hodnot statistického souboru dělený počtem pozorování.

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

kde

- $\bar{x}$  je aritmetický průměr,
- $\sum$  je sumační znak (součet hodnot),
- $x_i$  je  $i$ -tá hodnota statistického souboru,
- $i$  je index hodnoty,
- $n$  je počet pozorování.

## Implementace v R

| Funkce               | Příklad použití                         | Vysvětlení                                            |
|----------------------|-----------------------------------------|-------------------------------------------------------|
| <code>mean(x)</code> | <pre>x &lt;- c(1,2,3,4,5) mean(x)</pre> | Vrací aritmetický průměr hodnot ve vektoru <b>x</b> . |

## Implementace v Python

| Funkce                  | Příklad použití                                                    | Vysvětlení                                                   |
|-------------------------|--------------------------------------------------------------------|--------------------------------------------------------------|
| <code>np.mean(x)</code> | <pre>import numpy as np x = np.array([1,2,3,4,5]) np.mean(x)</pre> | Vrací aritmetický průměr pole pomocí knihovny <b>numpy</b> . |

### 1.2.2 Vážený aritmetický průměr (z četnostní tabulky)

Pokud jsou data zadána pomocí četnostní tabulky, aritmetický průměr lze vypočítat jako vážený průměr hodnot.

$$\bar{x} = \frac{\sum_{i=1}^k x_i n_i}{\sum_{i=1}^k n_i}$$

kde

- $\bar{x}$  je aritmetický průměr,

- $\sum$  je sumační znak (součet),
- $x_i$  je  $i$ -tá hodnota znaku,
- $n_i$  je absolutní četnost  $i$ -té hodnoty,
- $k$  je počet různých hodnot nebo tříd,
- $\sum_{i=1}^k n_i$  je celkový počet pozorování.

### Implementace v R

| Funkce                           | Příklad použití                                                   | Vysvětlení                                                         |
|----------------------------------|-------------------------------------------------------------------|--------------------------------------------------------------------|
| <code>weighted.mean(x, w)</code> | <pre>x &lt;- c(1,2,3) w &lt;- c(2,3,5)  weighted.mean(x, w)</pre> | Vrací vážený průměr hodnot ve vektoru <b>x</b> s váhami <b>w</b> . |

### Implementace v Python

| Funkce                                | Příklad použití                                                                                      | Vysvětlení                                                         |
|---------------------------------------|------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------|
| <code>np.average(x, weights=w)</code> | <pre>import numpy as np  x = np.array([1,2,3]) w = np.array([2,3,5])  np.average(x, weights=w)</pre> | Vrací vážený průměr hodnot ve vektoru <b>x</b> s váhami <b>w</b> . |

### 1.2.3 Aritmetický průměr pomocí relativních četností

Pokud jsou data vyjádřena pomocí relativních četností, lze aritmetický průměr vypočítat jako vážený součet hodnot.

$$\bar{x} = \sum_{i=1}^k x_i p_i$$

kde

- $\bar{x}$  je aritmetický průměr,
- $\sum$  je sumační znak (součet),
- $x_i$  je  $i$ -tá hodnota znaku,
- $p_i$  je relativní četnost  $i$ -té hodnoty,
- $i$  je index hodnoty,
- $k$  je počet různých hodnot nebo tříd.

### Implementace v R

| Funkce                  | Příklad použití                                                | Vysvětlení                                                      |
|-------------------------|----------------------------------------------------------------|-----------------------------------------------------------------|
| <code>sum(x * p)</code> | <pre>x &lt;- c(1,2,3) p &lt;- c(0.2,0.3,0.5)  sum(x * p)</pre> | Vrací aritmetický průměr vypočtený pomocí relativních četností. |



## Implementace v Python

| Funkce                     | Příklad použití                                                                                 | Vysvětlení                                                                                          |
|----------------------------|-------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------|
| <code>np.sum(x * p)</code> | <pre>import numpy as np  x = np.array([1,2,3]) p = np.array([0.2,0.3,0.5])  np.sum(x * p)</pre> | Vrací aritmetický průměr vypočtený pomocí relativních četností pomocí knihovny <code>numpy</code> . |

### 1.2.4 Harmonický průměr

Harmonický průměr je definován jako podíl počtu pozorování a součtu převrácených hodnot jednotlivých pozorování.

$$\bar{x}_H = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}$$

kde

- $\bar{x}_H$  je harmonický průměr,
- $n$  je počet pozorování,
- $\sum$  je sumační znak (součet),
- $x_i$  je  $i$ -tá hodnota statistického souboru,
- $\frac{1}{x_i}$  je převrácená hodnota  $i$ -tého pozorování.

## Implementace v R

| Funkce                    | Příklad použití                                               | Vysvětlení                                                 |
|---------------------------|---------------------------------------------------------------|------------------------------------------------------------|
| <code>n / sum(1/x)</code> | <pre>x &lt;- c(1,2,4,5) n &lt;- length(x)  n / sum(1/x)</pre> | Vrací harmonický průměr hodnot ve vektoru <code>x</code> . |

## Implementace v Python

| Funkce                            | Příklad použití                                                   | Vysvětlení                                                                                     |
|-----------------------------------|-------------------------------------------------------------------|------------------------------------------------------------------------------------------------|
| <code>scipy.stats.hmean(x)</code> | <pre>from scipy.stats import hmean  x = [1,2,4,5]  hmean(x)</pre> | Vrací harmonický průměr pomocí funkce <code>hmean</code> z knihovny <code>scipy.stats</code> . |

### 1.2.5 Geometrický průměr

Geometrický průměr je definován jako  $n$ -tá odmocnina součinu všech hodnot statistického souboru.

$$\bar{x}_G = \sqrt[n]{\prod_{i=1}^n x_i} = \sqrt[n]{x_1 \cdot x_2 \cdots x_n}$$

kde

- $\bar{x}_G$  je geometrický průměr,
- $\prod$  je znak pro součin (násobení všech hodnot),
- $x_i$  je  $i$ -tá hodnota statistického souboru,
- $i$  je index hodnoty,
- $n$  je počet pozorování,
- $\sqrt[n]{\phantom{x}}$  značí  $n$ -tou odmocninu.

### Implementace v R

| Funkce                         | Příklad použití                                 | Vysvětlení                                                  |
|--------------------------------|-------------------------------------------------|-------------------------------------------------------------|
| <code>exp(mean(log(x)))</code> | <pre>x &lt;- c(1,2,3,4) exp(mean(log(x)))</pre> | Vrací geometrický průměr hodnot ve vektoru <code>x</code> . |

### Implementace v Python

| Funkce                            | Příklad použití                                                 | Vysvětlení                                                                                      |
|-----------------------------------|-----------------------------------------------------------------|-------------------------------------------------------------------------------------------------|
| <code>scipy.stats.gmean(x)</code> | <pre>from scipy.stats import gmean x = [1,2,3,4] gmean(x)</pre> | Vrací geometrický průměr pomocí funkce <code>gmean</code> z knihovny <code>scipy.stats</code> . |

### 1.2.6 Vztah mezi průměry

$$\bar{x}_H \leq \bar{x}_G \leq \bar{x}$$

kde

- $\bar{x}_H$  je harmonický průměr,
- $\bar{x}_G$  je geometrický průměr,
- $\bar{x}$  je aritmetický průměr.

### 1.2.7 Medián

Medián je hodnota, která rozděluje uspořádaný statistický soubor na dvě stejně početné části. Medián také vyjadřuje 50% kvantil.

$$\tilde{x} = \begin{cases} x_{(\frac{n+1}{2})}, & \text{je-li } n \text{ liché,} \\ \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2}, & \text{je-li } n \text{ sudé.} \end{cases}$$

kde

- $\tilde{x}$  je medián,
- $x_{(i)}$  je  $i$ -tá hodnota v uspořádaném statistickém souboru,
- $n$  je počet pozorování.

### Implementace v R

| Funkce                 | Příklad použití                           | Vysvětlení                           |
|------------------------|-------------------------------------------|--------------------------------------|
| <code>median(x)</code> | <pre>x &lt;- c(1,3,2,5,4) median(x)</pre> | Vrací medián hodnot ve vektoru $x$ . |

### Implementace v Python

| Funkce                    | Příklad použití                                                       | Vysvětlení                           |
|---------------------------|-----------------------------------------------------------------------|--------------------------------------|
| <code>np.median(x)</code> | <pre>import numpy as np  x = np.array([1,3,2,5,4]) np.median(x)</pre> | Vrací medián hodnot ve vektoru $x$ . |

### 1.2.8 Kvantily a kvartily

Kvantily rozdělují uspořádaný statistický soubor na části se stejným počtem pozorování.  $q$ -kvantil je hodnota  $x_q$ , pro kterou platí

$$P(X \leq x_q) = q$$

kde

- $x_q$  je  $q$ -kvantil,
- $q \in (0, 1)$  je pořadí kvantilu,
- $P(X \leq x_q)$  je pravděpodobnost, že náhodná veličina nabývá hodnot menších nebo rovných  $x_q$ .

Speciálním případem kvantilů jsou kvartily, které rozdělují data na čtyři stejně velké části.

$$Q_1 = x_{0.25}, \quad Q_2 = x_{0.5}, \quad Q_3 = x_{0.75}$$

kde

- $Q_1$  je první kvartil (25% dat je menších),
- $Q_2$  je druhý kvartil, který odpovídá mediánu,
- $Q_3$  je třetí kvartil (75% dat je menších).

### Implementace v R

| Funkce                                             | Příklad použití                                                           | Vysvětlení                          |
|----------------------------------------------------|---------------------------------------------------------------------------|-------------------------------------|
| <code>quantile(x)</code>                           | <pre>x &lt;- c(1,2,3,4,5,6,7,8) quantile(x)</pre>                         | Vrací kvantily datového vektoru.    |
| <code>quantile(x, probs=c(0.25, 0.5, 0.75))</code> | <pre>x &lt;- c(1,2,3,4,5,6,7,8) quantile(x, probs=c(0.25,0.5,0.75))</pre> | Vrací první, druhý a třetí kvartil. |

### Implementace v Python

| Funkce                                       | Příklad použití                                                                              | Vysvětlení                          |
|----------------------------------------------|----------------------------------------------------------------------------------------------|-------------------------------------|
| <code>np.quantile(x,q)</code>                | <pre>import numpy as np x = np.array([1,2,3,4,5,6,7,8]) np.quantile(x,0.5)</pre>             | Vrací $q$ -kvantil pole.            |
| <code>np.quantile(x, [0.25,0.5,0.75])</code> | <pre>import numpy as np x = np.array([1,2,3,4,5,6,7,8]) np.quantile(x,[0.25,0.5,0.75])</pre> | Vrací první, druhý a třetí kvartil. |

### 1.2.9 Interkvartilové rozpětí (IQR)

Interkvartilové rozpětí (IQR) je rozdíl mezi třetím a prvním kvantilem. Vyjadřuje rozptyl prostředních 50 % dat.

$$IQR = Q_3 - Q_1$$

kde

- $IQR$  je interkvartilové rozpětí,
- $Q_1$  je první kvartil,
- $Q_3$  je třetí kvartil.

### Implementace v R

| Funkce              | Příklad použití                              | Vysvětlení                                      |
|---------------------|----------------------------------------------|-------------------------------------------------|
| <code>IQR(x)</code> | <pre>x &lt;- c(1,2,3,4,5,6,7,8) IQR(x)</pre> | Vrací interkvartilové rozpětí datového vektoru. |

## Implementace v Python

| Funkce                                                                    | Příklad použití                                                                                           | Vysvětlení                          |
|---------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------|-------------------------------------|
| <code>np.quantile(x,0.75)</code><br>-<br><code>np.quantile(x,0.25)</code> | <pre>import numpy as np x = np.array([1,2,3,4,5,6,7,8])  np.quantile(x,0.75) - np. quantile(x,0.25)</pre> | Vrací interkvartilové rozpětí pole. |

### 1.2.10 Modus

Modus je hodnota, která se ve statistickém souboru vyskytuje nejčastěji (s nejvyšší absolutní četností). Soubor může mít i více modů. U spojitých proměnných se modus stanovuje po diskretizaci do intervalů.

$$\hat{x} = x_{\arg \max_i n_i}$$

kde

- $\hat{x}$  je modus,
- $n_i$  je absolutní četnost  $i$ -té hodnoty,
- $\arg \max_i$  označuje index hodnoty s nejvyšší četností.

## Implementace v R

| Funkce                                  | Příklad použití                                                      | Vysvětlení                                      |
|-----------------------------------------|----------------------------------------------------------------------|-------------------------------------------------|
| <code>names(which.max(table(x)))</code> | <pre>x &lt;- c(1, 2, 2, 3, 3, 3, 4) names(which.max(table(x)))</pre> | Vrací modus (nejčastější hodnotu) vektoru $x$ . |

## Implementace v Python

| Funkce                          | Příklad použití                                                           | Vysvětlení                                      |
|---------------------------------|---------------------------------------------------------------------------|-------------------------------------------------|
| <code>statistics.mode(x)</code> | <pre>import statistics x = [1, 2, 2, 3, 3, 3, 4] statistics.mode(x)</pre> | Vrací modus pomocí standardní knihovny Pythonu. |

## 1.3 Charakteristiky variability

### 1.3.1 Variační rozpětí

Variační rozpětí je rozdíl mezi maximální a minimální hodnotou statistického souboru.

$$R = x_{\max} - x_{\min}$$

kde

- $R$  je variační rozpětí,
- $x_{\max}$  je maximální hodnota v souboru,
- $x_{\min}$  je minimální hodnota v souboru.

### Implementace v R

| Funkce                       | Příklad použití                                  | Vysvětlení                                                |
|------------------------------|--------------------------------------------------|-----------------------------------------------------------|
| <code>max(x) - min(x)</code> | <pre>x &lt;- c(3,7,2,9,5)  max(x) - min(x)</pre> | Vrací variační rozpětí hodnot ve vektoru <code>x</code> . |

### Implementace v Python

| Funkce                             | Příklad použití                                                                 | Vysvětlení                                                |
|------------------------------------|---------------------------------------------------------------------------------|-----------------------------------------------------------|
| <code>np.max(x) - np.min(x)</code> | <pre>import numpy as np  x = np.array([3,7,2,9,5])  np.max(x) - np.min(x)</pre> | Vrací variační rozpětí hodnot ve vektoru <code>x</code> . |

### 1.3.2 Rozptyl statistického souboru

Rozptyl vyjadřuje průměrnou kvadratickou odchylku hodnot od aritmetického průměru.

$$s_x^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

kde

- $s_x^2$  je rozptyl statistického souboru,
- $\sum$  je sumační znak (součet),
- $x_i$  je  $i$ -tá hodnota statistického souboru,
- $\bar{x}$  je aritmetický průměr,
- $x_i - \bar{x}$  je odchylka hodnoty od průměru,
- $(x_i - \bar{x})^2$  je čtverec odchylky,
- $n$  je počet pozorování.

Výpočetní tvar rozptylu:

$$s_x^2 = \frac{\sum_{i=1}^n x_i^2}{n} - \left( \frac{\sum_{i=1}^n x_i}{n} \right)^2$$

### Implementace v R

| Funkce                             | Příklad použití                                    | Vysvětlení                                                              |
|------------------------------------|----------------------------------------------------|-------------------------------------------------------------------------|
| <code>mean((x - mean(x))^2)</code> | <pre>x &lt;- c(2,4,6,8)  mean((x-mean(x))^2)</pre> | Vrací nevýběrový (populační) rozptyl hodnot ve vektoru <code>x</code> . |

### Implementace v Python

| Funkce                 | Příklad použití                                                   | Vysvětlení                                                                |
|------------------------|-------------------------------------------------------------------|---------------------------------------------------------------------------|
| <code>np.var(x)</code> | <pre>import numpy as np  x = np.array([2,4,6,8])  np.var(x)</pre> | Vrací nevýběrový (populační) rozptyl pomocí knihovny <code>numpy</code> . |

### 1.3.3 Výběrový rozptyl

Výběrový rozptyl je nezkreslený odhad rozptylu populace a vznikne úpravou rozptylu statistického souboru pomocí Besselovy korekce.

$$S^2 = \frac{n}{n-1} s_x^2$$

kde

- $S^2$  je výběrový rozptyl,
- $s_x^2$  je rozptyl statistického souboru,
- $n$  je počet pozorování,
- $n-1$  je korekce při odhadu rozptylu (Besselova korekce).

#### Implementace v R

| Funkce              | Příklad použití                       | Vysvětlení                                                                |
|---------------------|---------------------------------------|---------------------------------------------------------------------------|
| <code>var(x)</code> | <pre>x &lt;- c(2,4,6,8)  var(x)</pre> | Vrací výběrový rozptyl hodnot ve vektoru <code>x</code> (dělí se $n-1$ ). |

#### Implementace v Python

| Funkce                         | Příklad použití                                                           | Vysvětlení                                                                     |
|--------------------------------|---------------------------------------------------------------------------|--------------------------------------------------------------------------------|
| <code>np.var(x, ddof=1)</code> | <pre>import numpy as np  x = np.array([2,4,6,8])  np.var(x, ddof=1)</pre> | Vrací výběrový rozptyl pomocí knihovny <code>numpy</code> (Besselova korekce). |

### 1.3.4 Vážený rozptyl

Vážený rozptyl vyjadřuje variabilitu hodnot znaku, když mají jednotlivé hodnoty různé váhy nebo relativní četnosti.

$$s^2 = \sum_{i=1}^k p_i (x_i - \bar{x})^2$$

kde

- $s^2$  je vážený rozptyl,

- $x_i$  je  $i$ -tá hodnota znaku,
- $\bar{x}$  je vážený aritmetický průměr,
- $p_i$  je váha nebo relativní četnost  $i$ -té hodnoty,
- $k$  je počet různých hodnot nebo tříd.

### Implementace v R

| Funkce                                       | Příklad použití                                                                                       | Vysvětlení                                 |
|----------------------------------------------|-------------------------------------------------------------------------------------------------------|--------------------------------------------|
| <code>weighted.mean((x-mean(x))^2, w)</code> | <pre>x &lt;- c(1,2,3,4) w &lt;- c(0.1,0.2,0.3,0.4)  weighted.mean((x-weighted.mean(x, w))^2, w)</pre> | Vrací vážený rozptyl hodnot s váhami $w$ . |

### Implementace v Python

| Funkce                                          | Příklad použití                                                                                                                                            | Vysvětlení                                                      |
|-------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------|
| <code>np.average((x-xbar)**2, weights=w)</code> | <pre>import numpy as np  x = np.array([1,2,3,4]) w = np.array([0.1,0.2,0.3,0.4])  xbar = np.average(x, weights=w) np.average((x-xbar)**2, weights=w)</pre> | Vrací vážený rozptyl hodnot s váhami $w$ pomocí knihovny numpy. |

### 1.3.5 Směrodatná odchylka statistického souboru

Směrodatná odchylka je druhá odmocnina rozptylu statistického souboru.

$$s_x = \sqrt{s_x^2}$$

kde

- $s_x$  je směrodatná odchylka,
- $s_x^2$  je rozptyl statistického souboru,
- $\sqrt{\cdot}$  značí druhou odmocninu.

### Implementace v R

| Funkce                                 | Příklad použití                                          | Vysvětlení                                        |
|----------------------------------------|----------------------------------------------------------|---------------------------------------------------|
| <code>sqrt(mean((x-mean(x))^2))</code> | <pre>x &lt;- c(2,4,6,8)  sqrt(mean((x-mean(x))^2))</pre> | Vrací směrodatnou odchylku statistického souboru. |

### Implementace v Python



| Funkce                 | Příklad použití                                                   | Vysvětlení                                     |
|------------------------|-------------------------------------------------------------------|------------------------------------------------|
| <code>np.std(x)</code> | <pre>import numpy as np  x = np.array([2,4,6,8])  np.std(x)</pre> | Vrací směrodatnou odchylku pole (nevýběrovou). |

### 1.3.6 Výběrová směrodatná odchylka

Výběrová směrodatná odchylka je odmocnina z výběrového rozptylu.

$$S = \sqrt{S^2}$$

kde

- $S$  je výběrová směrodatná odchylka,
- $S^2$  je výběrový rozptyl,
- $\sqrt{\cdot}$  značí druhou odmocninu.

#### Implementace v R

| Funkce             | Příklad použití                      | Vysvětlení                                               |
|--------------------|--------------------------------------|----------------------------------------------------------|
| <code>sd(x)</code> | <pre>x &lt;- c(2,4,6,8)  sd(x)</pre> | Vrací výběrovou směrodatnou odchylku (dělí se $n - 1$ ). |

#### Implementace v Python

| Funkce                         | Příklad použití                                                           | Vysvětlení                                                |
|--------------------------------|---------------------------------------------------------------------------|-----------------------------------------------------------|
| <code>np.std(x, ddof=1)</code> | <pre>import numpy as np  x = np.array([2,4,6,8])  np.std(x, ddof=1)</pre> | Vrací výběrovou směrodatnou odchylku (Besselova korekce). |

### 1.3.7 Variační koeficient

Variační koeficient vyjadřuje relativní variabilitu dat a udává poměr směrodatné odchylky k aritmetickému průměru.

$$v_x = \frac{s_x}{\bar{x}}$$

kde

- $v_x$  je variační koeficient,
- $s_x$  je směrodatná odchylka,
- $\bar{x}$  je aritmetický průměr.

### Implementace v R

| Funkce                       | Příklad použití                                | Vysvětlení                                                   |
|------------------------------|------------------------------------------------|--------------------------------------------------------------|
| <code>sd(x) / mean(x)</code> | <pre>x &lt;- c(2,4,6,8)  sd(x) / mean(x)</pre> | Vrací variační koeficient hodnot ve vektoru <code>x</code> . |

### Implementace v Python

| Funkce                                      | Příklad použití                                                                        | Vysvětlení                                                                                                                                              |
|---------------------------------------------|----------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------|
| <code>np.std(x, ddof=1) / np.mean(x)</code> | <pre>import numpy as np  x = np.array([2,4,6,8])  np.std(x, ddof=1) / np.mean(x)</pre> | Vrací variační koeficient hodnot ve vektoru <code>x</code> . <code>ddof=1</code> odpovídá výběrové SD (dělí $n-1$ ), stejně jako <code>sd()</code> v R. |

### 1.3.8 Střední absolutní odchylka (MAD)

Střední absolutní odchylka (medián absolutních odchylek od mediánu) je robustní míra variability odolná vůči odlehlým hodnotám.

$$\text{MAD} = \text{median}(|x_i - \tilde{x}|)$$

kde

- MAD je střední absolutní odchylka,
- $x_i$  jsou hodnoty statistického souboru,
- $\tilde{x}$  je medián,
- $|\cdot|$  označuje absolutní hodnotu.

### Implementace v R

| Funkce              | Příklad použití                                                                                         | Vysvětlení                                                                                  |
|---------------------|---------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------|
| <code>mad(x)</code> | <pre>x &lt;- c(2, 4, 6, 8, 100) mad(x) # škálovaný (x 1.4826) mad(x, constant=1)# neškálovaný MAD</pre> | R automaticky škáluje MAD faktorem 1,4826 pro konzistenci se $\sigma$ normálního rozdělení. |

### Implementace v Python

| Funkce                                           | Příklad použití                                                                                   | Vysvětlení                             |
|--------------------------------------------------|---------------------------------------------------------------------------------------------------|----------------------------------------|
| <code>np.median(np.abs(x - np.median(x)))</code> | <pre>import numpy as np x = np.array([2, 4, 6, 8, 100]) np.median(np.abs(x - np.median(x)))</pre> | Neškálovaný MAD pomocí knihovny numpy. |

### 1.3.9 Detekce odlehlých hodnot – Tukeyovy meze

Hodnota je považována za odlehlou (outlier), pokud leží mimo interval ohraničený Tukeyovými mezemi. Tyto meze zobrazuje boxplot automaticky.

$$\text{dolní mez} = Q_1 - 1,5 \cdot IQR, \quad \text{horní mez} = Q_3 + 1,5 \cdot IQR$$

kde

- $Q_1$  je první kvartil,
- $Q_3$  je třetí kvartil,
- $IQR = Q_3 - Q_1$  je interkvartilové rozpětí.

#### Implementace v R

| Funkce        | Příklad použití                                                                                                                                                                       | Vysvětlení                                                                         |
|---------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------|
| Tukeyovy meze | <pre>q1 &lt;- quantile(x, 0.25) q3 &lt;- quantile(x, 0.75) iqr &lt;- IQR(x) dolni &lt;- q1 - 1.5 * iqr horni &lt;- q3 + 1.5 * iqr outliers &lt;- x[x &lt; dolni   x &gt; horni]</pre> | Identifikace odlehlých hodnot. Boxplot tyto meze zobrazuje automaticky jako vousy. |

#### Implementace v Python

| Funkce        | Příklad použití                                                                                                                                                           | Vysvětlení                     |
|---------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------|
| Tukeyovy meze | <pre>import numpy as np q1, q3 = np.quantile(x, [0.25, 0.75]) iqr = q3 - q1 outliers = x[(x &lt; q1 - 1.5*iqr)                               (x &gt; q3 + 1.5*iqr)]</pre> | Identifikace odlehlých hodnot. |

## 2 Teorie pravděpodobnosti

### 2.1 Počet pravděpodobnosti

#### 2.1.1 Klasická definice pravděpodobnosti

Pravděpodobnost jevu  $A$  při klasické definici pravděpodobnosti je podíl počtu příznivých výsledků a celkového počtu stejně pravděpodobných výsledků.

$$P(A) = \frac{m}{n}$$

kde

- $P(A)$  je pravděpodobnost jevu  $A$ ,
  - $m$  je počet příznivých výsledků,
  - $n$  je počet všech možných výsledků.
- 

#### 2.1.2 Pravděpodobnost komplementárního jevu

Pravděpodobnost opačného (komplementárního, doplňkového) jevu k jevu  $A$  je rovna jedné minus pravděpodobnost jevu  $A$ .

$$P(\overline{A}) = 1 - P(A)$$

kde

- $P(\overline{A})$  je pravděpodobnost opačného jevu k  $A$ ,
  - $P(A)$  je pravděpodobnost jevu  $A$ .
- 

#### 2.1.3 Horní odhad pravděpodobnosti průniku

Pravděpodobnost současného nastání dvou jevů nemůže být větší než pravděpodobnost kteréhokolik z nich.

$$P(A \cap B) \leq \min(P(A), P(B))$$

kde

- $P(A \cap B)$  je pravděpodobnost, že nastanou oba jevy současně,
  - $P(A)$  je pravděpodobnost jevu  $A$ ,
  - $P(B)$  je pravděpodobnost jevu  $B$ ,
  - $\min(\cdot)$  označuje minimum z daných hodnot.
- 

#### 2.1.4 Průnik nezávislých jevů

Jsou-li jevy  $A$  a  $B$  nezávislé, pak pravděpodobnost jejich současného nastání je rovna součinu jejich pravděpodobností.

$$P(A \cap B) = P(A)P(B)$$

kde

- $P(A \cap B)$  je pravděpodobnost současného nastání jevů  $A$  a  $B$ ,
  - $P(A)$  je pravděpodobnost jevu  $A$ ,
  - $P(B)$  je pravděpodobnost jevu  $B$ .
-

### 2.1.5 Sjednocení dvou jevů

Pravděpodobnost, že nastane alespoň jeden z jevů  $A$  nebo  $B$ , je rovna součtu jejich pravděpodobností minus pravděpodobnost jejich současného nastání.

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

kde

- $P(A \cup B)$  je pravděpodobnost, že nastane alespoň jeden z jevů,
  - $P(A)$  je pravděpodobnost jevu  $A$ ,
  - $P(B)$  je pravděpodobnost jevu  $B$ ,
  - $P(A \cap B)$  je pravděpodobnost současného nastání jevů  $A$  a  $B$ .
- 

### 2.1.6 Sjednocení neslučitelných jevů

Pokud jsou jevy  $A$  a  $B$  neslučitelné (nemohou nastat současně), pak pravděpodobnost jejich sjednocení je rovna součtu pravděpodobností těchto jevů.

$$P(A \cup B) = P(A) + P(B)$$

kde

- $P(A \cup B)$  je pravděpodobnost, že nastane jev  $A$  nebo  $B$ ,
  - $P(A)$  je pravděpodobnost jevu  $A$ ,
  - $P(B)$  je pravděpodobnost jevu  $B$ .
- 

### 2.1.7 Podmíněná pravděpodobnost

Podmíněná pravděpodobnost jevu  $A$  za podmínky, že nastal jev  $B$ , je pravděpodobnost současného nastání jevů  $A$  a  $B$  dělená pravděpodobností  $B$ .

$$P(A | B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0$$

kde

- $P(A | B)$  je podmíněná pravděpodobnost jevu  $A$  za podmínky  $B$ ,
- $P(A \cap B)$  je pravděpodobnost současného nastání jevů  $A$  a  $B$ ,
- $P(B)$  je pravděpodobnost jevu  $B$ .

Jevy  $A$  a  $B$  jsou **nezávislé**, právě když  $P(A | B) = P(A)$ , tj. nastání  $B$  nemění pravděpodobnost  $A$ .

---

### 2.1.8 Věta o úplné pravděpodobnosti

Je-li  $\{B_1, B_2, \dots, B_k\}$  úplný systém jevů (vzájemně se vylučují a jejich sjednocení je jistý jev), pak pro libovolný jev  $A$  platí

$$P(A) = \sum_{j=1}^k P(A | B_j) P(B_j)$$

kde

- $P(A)$  je pravděpodobnost jevu  $A$ ,
- $B_1, \dots, B_k$  jsou vzájemně se vylučující jevy pokrývající celý prostor,
- $P(A | B_j)$  je podmíněná pravděpodobnost  $A$  za podmínky  $B_j$ ,
- $P(B_j)$  je pravděpodobnost jevu  $B_j$ .

## 2.2 Náhodné veličiny

### 2.2.1 Pravděpodobnostní funkce diskrétní náhodné veličiny

Pravděpodobnost, že diskrétní náhodná veličina  $X$  nabývá konkrétní hodnoty  $x$ .

$$P(x) = P(X = x)$$

kde

- $P(x)$  je pravděpodobnost hodnoty  $x$ ,
  - $P(X = x)$  je pravděpodobnost, že náhodná veličina  $X$  má hodnotu  $x$ ,
  - $X$  je náhodná veličina,
  - $x$  je konkrétní hodnota náhodné veličiny.
- 

### 2.2.2 Distribuční funkce diskrétní náhodné veličiny

Distribuční funkce (kumulativní pravděpodobnost) udává pravděpodobnost, že náhodná veličina  $X$  bude menší nebo rovna hodnotě  $x$ .

$$F(x) = P(X \leq x) = \sum_{x_j \leq x} P(x_j)$$

kde

- $F(x)$  je distribuční funkce,
  - $P(X \leq x)$  je pravděpodobnost, že  $X$  je menší nebo rovno  $x$ ,
  - $\sum$  je součet pravděpodobností,
  - $x_j$  jsou jednotlivé možné hodnoty náhodné veličiny,
  - $P(x_j)$  je pravděpodobnost, že  $X = x_j$ .
- 

### 2.2.3 Pravděpodobnost intervalu

Pravděpodobnost, že náhodná veličina  $X$  nabývá hodnot v intervalu  $(x_1, x_2]$ .

$$P(x_1 < X \leq x_2) = \sum_{x_1 < x \leq x_2} P(x) = F(x_2) - F(x_1)$$

kde

- $P(x_1 < X \leq x_2)$  je pravděpodobnost, že  $X$  leží mezi  $x_1$  a  $x_2$ ,
  - $X$  je náhodná veličina,
  - $x_1, x_2$  jsou hranice intervalu,
  - $\sum$  je součet pravděpodobností všech hodnot v intervalu,
  - $P(x)$  je pravděpodobnost, že  $X = x$ ,
  - $F(x)$  je distribuční funkce.
-

### 2.2.4 Střední hodnota diskrétní náhodné veličiny

Střední hodnota (očekávaná hodnota) diskrétní náhodné veličiny je vážený průměr všech možných hodnot, kde váhami jsou jejich pravděpodobnosti.

$$E(X) = \sum_x x P(x)$$

kde

- $E(X)$  je očekávaná hodnota náhodné veličiny  $X$ ,
  - $\sum$  je součet přes všechny možné hodnoty,
  - $x$  jsou jednotlivé možné hodnoty náhodné veličiny,
  - $P(x) = P(X = x)$  je pravděpodobnost, že  $X$  nabude hodnoty  $x$ .
- 

### 2.2.5 Rozptyl diskrétní náhodné veličiny

Rozptyl náhodné veličiny vyjadřuje míru variability hodnot náhodné veličiny kolem její střední hodnoty.

$$D(X) = E(X^2) - [E(X)]^2 = \sum_x x^2 P(x) - \left( \sum_x x P(x) \right)^2$$

kde

- $D(X)$  je rozptyl náhodné veličiny  $X$ ,
  - $E(X)$  je očekávaná hodnota náhodné veličiny,
  - $E(X^2)$  je očekávaná hodnota druhé mocniny náhodné veličiny,
  - $\sum$  je součet přes všechny možné hodnoty,
  - $x$  jsou jednotlivé možné hodnoty náhodné veličiny,
  - $P(x) = P(X = x)$  je pravděpodobnost, že  $X$  nabude hodnoty  $x$ .
- 

### 2.2.6 Hustota pravděpodobnosti spojitě náhodné veličiny

Hustota pravděpodobnosti vyjadřuje rychlost změny distribuční funkce spojitě náhodné veličiny.

$$f(x) = F'(x)$$

kde

- $f(x)$  je hustota pravděpodobnosti,
  - $F(x)$  je distribuční funkce,
  - $F'(x)$  je derivace distribuční funkce podle  $x$ ,
  - $x$  je hodnota náhodné veličiny.
-

### 2.2.7 Normalizační podmínka hustoty pravděpodobnosti

Celková pravděpodobnost spojité náhodné veličiny přes všechny možné hodnoty je rovna jedné.

$$\int_{-\infty}^{\infty} f(x) dx = 1$$

kde

- $\int$  označuje integrál (součet přes všechny hodnoty),
  - $f(x)$  je hustota pravděpodobnosti,
  - $dx$  je integrační proměnná,
  - $-\infty, \infty$  vyjadřují integraci přes všechny možné hodnoty náhodné veličiny.
- 

### 2.2.8 Distribuční funkce spojité náhodné veličiny

Distribuční funkce spojité náhodné veličiny udává pravděpodobnost, že náhodná veličina  $X$  bude menší nebo rovna hodnotě  $x$ .

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$$

kde

- $F(x)$  je distribuční funkce,
  - $P(X \leq x)$  je pravděpodobnost, že náhodná veličina  $X$  je menší nebo rovna  $x$ ,
  - $\int$  označuje integrál,
  - $f(t)$  je hustota pravděpodobnosti,
  - $t$  je integrační proměnná,
  - $-\infty$  je dolní mez integrace,
  - $x$  je horní mez integrace.
- 

### 2.2.9 Pravděpodobnost intervalu spojité náhodné veličiny

Pravděpodobnost, že spojitá náhodná veličina  $X$  nabývá hodnot v intervalu  $(x_1, x_2]$ .

$$P(x_1 < X \leq x_2) = \int_{x_1}^{x_2} f(x) dx = F(x_2) - F(x_1)$$

kde

- $P(x_1 < X \leq x_2)$  je pravděpodobnost, že  $X$  leží mezi  $x_1$  a  $x_2$ ,
  - $X$  je náhodná veličina,
  - $x_1, x_2$  jsou hranice intervalu,
  - $\int$  označuje integrál,
  - $f(x)$  je hustota pravděpodobnosti,
  - $dx$  je integrační proměnná,
  - $F(x)$  je distribuční funkce.
-



### 2.2.10 Střední hodnota spojitě náhodné veličiny

Střední hodnota (očekávaná hodnota) spojitě náhodné veličiny je vážený průměr všech možných hodnot, kde váhami jsou hodnoty hustoty pravděpodobnosti.

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx$$

kde

- $E(X)$  je očekávaná hodnota náhodné veličiny  $X$ ,
  - $\int$  označuje integrál,
  - $x$  je hodnota náhodné veličiny,
  - $f(x)$  je hustota pravděpodobnosti,
  - $dx$  je integrační proměnná,
  - $-\infty, \infty$  vyjadřují integraci přes všechny možné hodnoty náhodné veličiny.
- 

### 2.2.11 Rozptyl spojitě náhodné veličiny

Rozptyl spojitě náhodné veličiny vyjadřuje variabilitu hodnot náhodné veličiny kolem její střední hodnoty.

$$D(X) = \int_{-\infty}^{\infty} x^2 f(x) dx - \left[ \int_{-\infty}^{\infty} x f(x) dx \right]^2$$

kde

- $D(X)$  je rozptyl náhodné veličiny  $X$ ,
  - $\int$  označuje integrál,
  - $x$  je hodnota náhodné veličiny,
  - $f(x)$  je hustota pravděpodobnosti,
  - $dx$  je integrační proměnná,
  - $\int x f(x) dx$  je očekávaná hodnota  $E(X)$ ,
  - $\int x^2 f(x) dx$  je očekávaná hodnota  $E(X^2)$ .
- 

### 2.2.12 Směrodatná odchylka náhodné veličiny

Směrodatná odchylka vyjadřuje míru variability hodnot náhodné veličiny kolem její střední hodnoty.

$$\sigma = \sqrt{D(X)}$$

kde

- $\sigma$  je směrodatná odchylka,
- $D(X)$  je rozptyl náhodné veličiny  $X$ ,
- $\sqrt{\phantom{x}}$  označuje druhou odmocninu.

## 2.3 Vlastnosti střední hodnoty a rozptylu

### 2.3.1 Vlastnosti střední hodnoty $E(X)$

Pro libovolné náhodné veličiny  $X, Y$  a konstantu  $c$  platí:

$$E(c) = c, \quad E(cX) = cE(X), \quad E(X + c) = E(X) + c$$
$$E(X + Y) = E(X) + E(Y)$$

Pro **nezávislé** náhodné veličiny  $X$  a  $Y$  navíc platí:

$$E(X \cdot Y) = E(X) \cdot E(Y)$$

kde

- $E(\cdot)$  označuje střední hodnotu (očekávanou hodnotu),
- $c$  je konstanta,
- $X, Y$  jsou náhodné veličiny.

#### Implementace v R

| Funkce                   | Příklad použití                                                                                            | Vysvětlení                         |
|--------------------------|------------------------------------------------------------------------------------------------------------|------------------------------------|
| <code>mean(c * X)</code> | <pre>c1 &lt;- 3 X &lt;- c(1, 2, 3, 4, 5) mean(c1 * X) # = c1 * mean(X) mean(X + c1) # = mean(X) + c1</pre> | Ověření linearity střední hodnoty. |

### 2.3.2 Vlastnosti rozptylu $D(X)$

Pro libovolnou náhodnou veličinu  $X$  a konstantu  $c$  platí:

$$D(c) = 0, \quad D(cX) = c^2 D(X), \quad D(X + c) = D(X)$$

Pro **nezávislé** náhodné veličiny  $X$  a  $Y$  navíc platí:

$$D(X + Y) = D(X) + D(Y)$$

kde

- $D(\cdot)$  označuje rozptyl,
- $c$  je konstanta,
- $X, Y$  jsou nezávislé náhodné veličiny.

#### Implementace v R

| Funkce                      | Příklad použití                                                                                                                    | Vysvětlení                                                                         |
|-----------------------------|------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------|
| <code>var_pop(c * X)</code> | <pre>var_pop &lt;- function(x) mean((x-   mean(x))^2) var_pop(c1 * X) # = c1^2 *   var_pop(X) var_pop(X + c1) # = var_pop(X)</pre> | Vlastnosti populačního rozptylu (dělí $n$ ); <code>var()</code> v R dělí $n - 1$ . |

### 3 Kombinatorika a Metriky

#### 3.1 Kombinatorika

Mějme množinu  $n$  prvků, ze které vybíráme  $k$  prvků.

- **Permutace (Pořadí všech  $n$  prvků):** Bez opakování:  $P(n) = n!$   
S opakováním:  $P'_{k_1, \dots, k_m}(n) = \frac{n!}{k_1! \dots k_m!}$
- **Variace (Výběr  $k$  prvků z  $n$ , záleží na pořadí):** Bez opakování:  $V(k, n) = \frac{n!}{(n-k)!}$   
S opakováním:  $V'(k, n) = n^k$
- **Kombinace (Výběr  $k$  prvků z  $n$ , nezáleží na pořadí):** Bez opakování:  $K(k, n) = \binom{n}{k} = \frac{n!}{k!(n-k)!}$   
S opakováním:  $K'(k, n) = \binom{n+k-1}{k} = \frac{(n+k-1)!}{k!(n-1)!}$

#### 3.2 $L^p$ Normy (Vzdálenosti a penalizace)

Obecně:  $\|x\|_p = (\sum |x_i|^p)^{1/p}$ . Klíčové pro metriky chyb a regularizaci.

- $L^1$  (**Manhattan**):  $\|x\|_1 = \sum |x_i|$ . Využití: Lasso regrese.
- $L^2$  (**Euklid**):  $\|x\|_2 = \sqrt{\sum x_i^2}$ . Využití: Ridge regrese (metoda nejmenších čtverců).
- $L^\infty$  (**Max**):  $\|x\|_\infty = \max(|x_i|)$ . Reprezentuje nejhorší možnou chybu.

## 4 Pravděpodobnostní rozdělení

### 4.1 Diskrétní rozdělení

#### 4.1.1 Binomické rozdělení $\text{Bin}(n, p)$

Popisuje počet úspěchů v  $n$  nezávislých pokusech, kde pravděpodobnost úspěchu v každém pokusu je  $p$ .

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n$$

$$E(X) = np, \quad D(X) = np(1-p)$$

kde

- $n$  je počet pokusů,
- $p$  je pravděpodobnost úspěchu v jednom pokusu,
- $k$  je počet úspěchů,
- $\binom{n}{k} = \frac{n!}{k!(n-k)!}$  je kombinační číslo.

#### Implementace v R

| Funkce                       | Příklad použití                                                                                                                                                               | Vysvětlení                                                       |
|------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------|
| <code>dbinom(k, n, p)</code> | <pre>dbinom(3, size=10, prob=0.3) # P(X=3) pbinom(3, size=10, prob=0.3) # P(X&lt;=3) qbinom(0.9, size=10, prob=0.3) # kvantil rbinom(100, size=10, prob=0.3) # simulace</pre> | d/p/q/r = hustota / distribuční fce / kvantilová fce / simulace. |

#### Implementace v Python

| Funkce                                | Příklad použití                                                                                                                                          | Vysvětlení                                                |
|---------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------|
| <code>stats.binom.pmf(k, n, p)</code> | <pre>from scipy.stats import binom binom.pmf(3, n=10, p=0.3) # P(X=3) binom.cdf(3, n=10, p=0.3) # P(X&lt;=3) binom.ppf(0.9, n=10, p=0.3) # kvantil</pre> | Binomické rozdělení z knihovny <code>scipy.stats</code> . |

#### 4.1.2 Poissonovo rozdělení $\text{Pois}(\lambda)$

Popisuje počet náhodných událostí v daném časovém intervalu nebo oblasti, kdy průměrný počet událostí je  $\lambda$ . Vhodné pro vzácné jevy (velké  $n$ , malé  $p$ ).

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

$$E(X) = D(X) = \lambda$$

kde

- $\lambda > 0$  je průměrný počet událostí (intenzita),
- $k$  je počet událostí,
- $e \approx 2,718$  je Eulerovo číslo.

Aproximace: pro velké  $n$  a malé  $p$  platí  $\text{Bin}(n, p) \approx \text{Pois}(\lambda)$ , kde  $\lambda = np$ .

### Implementace v R

| Funkce                        | Příklad použití                                                                                                                       | Vysvětlení                                                       |
|-------------------------------|---------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------|
| <code>dpois(k, lambda)</code> | <pre>dpois(2, lambda=4) # P(X=2) ppois(2, lambda=4) # P(X&lt;=2) qpois(0.9, lambda=4) # kvantil rpois(100, lambda=4) # simulace</pre> | d/p/q/r = hustota / distribuční fce / kvantilová fce / simulace. |

### Implementace v Python

| Funkce                                | Příklad použití                                                                                            | Vysvětlení                                                 |
|---------------------------------------|------------------------------------------------------------------------------------------------------------|------------------------------------------------------------|
| <code>stats.poisson.pmf(k, mu)</code> | <pre>from scipy.stats import poisson poisson.pmf(2, mu=4) # P(X=2) poisson.cdf(2, mu=4) # P(X&lt;=2)</pre> | Poissonovo rozdělení z knihovny <code>scipy.stats</code> . |

#### 4.1.3 Hypergeometrické rozdělení $\text{Hyper}(N, K, n)$

Popisuje počet úspěchů při výběru  $n$  prvků **bez návratu** z populace  $N$  prvků, z nichž  $K$  je úspěšných. Rozdíl od binomického: pravděpodobnost úspěchu se mění s každým tahem.

$$P(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}, \quad k = \max(0, n + K - N), \dots, \min(n, K)$$

$$E(X) = \frac{nK}{N}, \quad D(X) = \frac{nK}{N} \cdot \frac{N-K}{N} \cdot \frac{N-n}{N-1}$$

kde

- $N$  je velikost populace,
- $K$  je počet úspěchů v populaci,
- $n$  je velikost výběru,
- $k$  je počet úspěchů ve výběru.

## Implementace v R

| Funkce                            | Příklad použití                                                                                                                                                                                                  | Vysvětlení                                                       |
|-----------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------|
| <code>dhyper(k, K, N-K, n)</code> | <pre># N=50, K=20 uspesnych, n=10 #          vybranych dhyper(3, m=20, n=30, k=10) # P( #          X=3) phyper(3, m=20, n=30, k=10) # P( #          X&lt;=3) # argumenty: m=K, n=N-K, k=vyber #          n</pre> | d/p/q/r = hustota / distribuční fce / kvantilová fce / simulace. |

## Implementace v Python

| Funkce                                    | Příklad použití                                                                                                                                                                                                            | Vysvětlení                                                       |
|-------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------|
| <code>stats.hypergeom.pmf(k,M,n,N)</code> | <pre>from scipy.stats import hypergeom hypergeom.pmf(3, M=50, n=20, N =10) # M = velikost populace (N v #      matematice) # n = pocet uspesnych v populaci #      (K) # N = velikost vyberu (n v #      matematice)</pre> | Hypergeometrické rozdělení z knihovny <code>scipy.stats</code> . |

## 4.2 Spojitá rozdělení

### 4.2.1 Normální rozdělení $N(\mu, \sigma^2)$


Nejdůležitější spojité rozdělení. Hustota pravděpodobnosti má tvar symetrické zvonové křivky kolem střední hodnoty  $\mu$ .

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}$$

$$E(X) = \mu, \quad D(X) = \sigma^2$$

kde

- $\mu$  je střední hodnota (poloha středu),
- $\sigma^2$  je rozptyl ( $\sigma > 0$  je směrodatná odchylka),
- $e \approx 2,718$  je Eulerovo číslo,  $\pi \approx 3,14159$ .



### Standardizace

Libovolnou normálně rozdělenou veličinu lze převést na standardní normální  $Z \sim N(0, 1)$ :

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

Standardní normální rozdělení má  $E(Z) = 0$  a  $D(Z) = 1$ .

### Pravidlo $6\sigma$

Oblast  $\pm 6\sigma$  kolem střední hodnoty pokrývá prakticky celou distribuci. Pravidlo se využívá v managementu kvality (metodologie *Six Sigma*):

$$P(\mu - 6\sigma \leq X \leq \mu + 6\sigma) \approx 0,9999999980$$

Procesy s variabilitou nepřesahující  $\pm 6\sigma$  od cílové hodnoty produkují méně než 3,4 závad na milion příležitostí (DPMO).

### Implementace v R

| Funkce                           | Příklad použití                                                                                                                                                                          | Vysvětlení                                                       |
|----------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------|
| dnorm / pnorm /<br>qnorm / rnorm | <pre>pnorm(185, mean=180, sd=7) # F(185) qnorm(0.975) # kvantil N(0,1) rnorm(100, mean=0, sd=1) #   simulace # standardizace (ekvivalentni): pnorm(185, 180, 7) pnorm((185-180)/7)</pre> | d/p/q/r = hustota / distribuční fce / kvantilová fce / simulace. |

### Implementace v Python

| Funkce                           | Příklad použití                                                                                                                                   | Vysvětlení                       |
|----------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------|
| stats.norm.cdf(x,<br>loc, scale) | <pre>from scipy.stats import norm norm.cdf(185, loc=180, scale=7)   # F(185) norm.ppf(0.975) # kvantil N(0,1) norm.rvs(size=100) # simulace</pre> | loc = $\mu$ , scale = $\sigma$ . |


#### 4.2.2 Rovnoměrné rozdělení $U(a, b)$

Každá hodnota v intervalu  $[a, b]$  je stejně pravděpodobná. Hustota pravděpodobnosti je na celém intervalu konstantní.

$$f(x) = \frac{1}{b-a}, \quad x \in [a, b], \quad f(x) = 0 \text{ jinak}$$

$$E(X) = \frac{a+b}{2}, \quad D(X) = \frac{(b-a)^2}{12}$$

kde  $a$  je dolní mez a  $b$  je horní mez intervalu.



### Implementace v R

| Funkce                           | Příklad použití                                                                                                                                                               | Vysvětlení            |
|----------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------|
| dunif / punif /<br>qunif / runif | <pre>dunif(0.5, min=0, max=1) #   hustota f(0.5) punif(0.5, min=0, max=1) # P(X   &lt;=0.5) qunif(0.75, min=0, max=1) #   kvantil runif(100, min=0, max=1) #   simulace</pre> | min= $a$ , max= $b$ . |

### Implementace v Python

| Funkce                        | Příklad použití                                                                                                                                                                             | Vysvětlení                  |
|-------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------|
| uniform.cdf(x,<br>loc, scale) | <pre>from scipy.stats import uniform # loc=a, scale=b-a uniform.pdf(0.5, loc=0, scale=1) uniform.cdf(0.5, loc=0, scale=1) # P(X&lt;=0.5) uniform.ppf(0.75, loc=0, scale =1) # kvantil</pre> | loc= $a$ , scale= $b - a$ . |


### 4.2.3 Exponenciální rozdělení $\text{Exp}(\lambda)$

Modeluje dobu čekání na první událost Poissonova procesu. Charakteristická vlastnost: **absence paměti** –  $P(X > s + t \mid X > s) = P(X > t)$ .

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0$$

$$E(X) = \frac{1}{\lambda}, \quad D(X) = \frac{1}{\lambda^2}$$

kde  $\lambda > 0$  je intenzita (průměrný počet událostí za jednotku času).



### Implementace v R

| Funkce                       | Příklad použití                                                                                                                                          | Vysvětlení        |
|------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------|
| dexp / pexp /<br>qexp / rexp | <pre>dexp(1, rate=0.5) # hustota f(1)   pro lambda=0.5 pexp(2, rate=0.5) # P(X&lt;=2) qexp(0.9, rate=0.5) # kvantil rexp(100, rate=0.5) # simulace</pre> | rate= $\lambda$ . |



## Implementace v Python

| Funkce                           | Příklad použití                                                                                                                                                                         | Vysvětlení                   |
|----------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------|
| <code>expon.cdf(x, scale)</code> | <pre>from scipy.stats import expon # scale = 1/lambda expon.pdf(1, scale=2) # hustota     pro lambda=0.5 expon.cdf(2, scale=2) # P(X&lt;=2) expon.ppf(0.9, scale=2) #     kvantil</pre> | $\text{scale} = 1/\lambda$ . |


## 4.3 Odvozená rozdělení

### 4.3.1 Studentovo t-rozdělení $t(\nu)$

Vzniká jako podíl standardní normální veličiny a odmocniny veličiny  $\chi^2$  dělené svými stupni volnosti. Klíčové pro testování hypotéz a intervaly spolehlivosti, když **neznáme rozptyl** populace  $\sigma^2$ .

$$E(X) = 0 \ (\nu > 1), \quad D(X) = \frac{\nu}{\nu - 2} \ (\nu > 2)$$

kde  $\nu$  jsou stupně volnosti. Pro  $\nu \rightarrow \infty$  přechází t-rozdělení v  $N(0, 1)$ .



## Implementace v R

| Funkce                         | Příklad použití                                                                                                                                  | Vysvětlení                           |
|--------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------|
| <code>dt / pt / qt / rt</code> | <pre>dt(0, df=5) # hustota f(0) pt(-1.96, df=19) # P(T&lt;=t) qt(0.975, df=19) # krit. hodnota     pro t-test/IS rt(100, df=10) # simulace</pre> | $\text{df} = \nu$ (stupně volnosti). |

## Implementace v Python


| Funkce                         | Příklad použití                                                                                                                                                                   | Vysvětlení                           |
|--------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------|
| <code>t.pdf / cdf / ppf</code> | <pre>from scipy.stats import t t.pdf(0, df=5) # hustota f(0) t.cdf(-1.96, df=19) # P(T&lt;=t) t.ppf(0.975, df=19) # krit.     hodnota t.rvs(df=10, size=100) #     simulace</pre> | $\text{df} = \nu$ (stupně volnosti). |

### 4.3.2 Chí-kvadrát rozdělení $\chi^2(k)$

Vzniká jako součet kvadrátů  $k$  nezávislých standardně normálních veličin. Použití: test dobré shody, test nezávislosti v kontingenční tabulce.

$$E(X) = k, \quad D(X) = 2k$$

kde  $k > 0$  jsou stupně volnosti. Rozdělení je pravostranně asymetrické; pro velká  $k$  se přibližuje normálnímu.



#### Implementace v R

| Funkce                                  | Příklad použití                                                                                                                                    | Vysvětlení                  |
|-----------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------|
| dchisq / pchisq<br>/ qchisq /<br>rchisq | <pre>dchisq(5, df=3) # hustota f(5) pchisq(7.81, df=3) # P(X&lt;=7.81) qchisq(0.95, df=3) # krit.       hodnota rchisq(100, df=3) # simulace</pre> | df = $k$ (stupně volnosti). |

#### Implementace v Python


| Funkce                  | Příklad použití                                                                                                                                                                                     | Vysvětlení                  |
|-------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------|
| chi2.pdf / cdf<br>/ ppf | <pre>from scipy.stats import chi2 chi2.pdf(5, df=3) # hustota f(5) chi2.cdf(7.81, df=3) # P(X     &lt;=7.81) chi2.ppf(0.95, df=3) # krit.     hodnota chi2.rvs(df=3, size=100) #     simulace</pre> | df = $k$ (stupně volnosti). |

### 4.3.3 F-rozdělení $F(k_1, k_2)$

Vzniká jako podíl dvou nezávislých veličin  $\chi^2$ , každé dělené svými stupni volnosti. Použití: ANOVA, F-test celkové platnosti regresního modelu.

$$E(X) = \frac{k_2}{k_2 - 2} \quad (k_2 > 2), \quad D(X) = \frac{2k_2^2(k_1 + k_2 - 2)}{k_1(k_2 - 2)^2(k_2 - 4)} \quad (k_2 > 4)$$

kde  $k_1$  jsou stupně volnosti čitatele a  $k_2$  jmenovatele.



## Implementace v R

| Funkce               | Příklad použití                                                                                                                                                                                                                                                                                                                                       | Vysvětlení                                     |
|----------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------|
| df / pf / qf /<br>rf | <pre>df(2, df1=3, df2=10) # hustota f                         (2) pf(3.71, df1=3, df2=10) # P(F                         &lt;=3.71) qf(0.95, df1=3, df2=10) # krit.                         hodnota rf(100, df1=3, df2=10) #                         simulace # pozor: df() koliduje s data.                         frame # pouzit: stats::df()</pre> | df1= $k_1$ (čitatel), df2= $k_2$ (jmenovatel). |

## Implementace v Python

| Funkce               | Příklad použití                                                                                                                                                                                                                                                                                              | Vysvětlení                                     |
|----------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------|
| f.pdf / cdf /<br>ppf | <pre>from scipy.stats import f f.pdf(2, dfn=3, dfd=10) #                         hustota f(2) f.cdf(3.71, dfn=3, dfd=10) # P(F                         &lt;=3.71) f.ppf(0.95, dfn=3, dfd=10) #                         krit. hodnota f.rvs(dfn=3, dfd=10, size=100) #                         simulace</pre> | dfn= $k_1$ (čitatel), dfd= $k_2$ (jmenovatel). |

## 5 Testování hypotéz

### 5.1 Chyby testování hypotéz

Rozhodnutí o zamítnutí  $H_0$  může být správné nebo chybné. **Hladina významnosti**  $\alpha = P(\text{chyba I. typu})$  se volí předem (typicky 0,05 nebo 0,01).

|                     | $H_0$ se nezamítá                      | $H_0$ se zamítá                                    |
|---------------------|----------------------------------------|----------------------------------------------------|
| $H_0$ je pravdivá   | Správné rozhodnutí<br>( $1 - \alpha$ ) | <b>Chyba I. typu</b><br>( $\alpha$ )               |
| $H_0$ není pravdivá | <b>Chyba II. typu</b><br>( $\beta$ )   | Správné rozhodnutí<br>( $1 - \beta$ ) = síla testu |

- $\alpha$  (**chyba I. typu**): zamítneme  $H_0$ , přestože platí. Volíme sami jako hladinu významnosti.
- $\beta$  (**chyba II. typu**): nezamítneme  $H_0$ , přestože neplatí. Závisí na velikosti výběru a síle efektu.
- $1 - \beta$  (**síla testu**): pravděpodobnost správného zamítnutí nepravdivé  $H_0$ .
- Snížení  $\alpha$  zpravidla zvyšuje  $\beta$  (při stejném  $n$ ).

### 5.2 Bodový odhad

Bodový odhad nahrazuje neznámý parametr populace jednou hodnotou vypočtenou z výběru. Výběrový průměr  $\bar{x}$  a výběrový rozptyl  $s^2$  jsou **nestranné** odhady (jejich střední hodnota se rovná odhadovanému parametru).

| Parametr              | Odhad (vzorec)                                                | Implementace v R                     |
|-----------------------|---------------------------------------------------------------|--------------------------------------|
| Střední hodnota $\mu$ | $\hat{\mu} = \bar{x} = \frac{1}{n} \sum x_i$                  | <code>mean(x)</code>                 |
| Rozptyl $\sigma^2$    | $\hat{\sigma}^2 = s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$ | <code>var(x)</code>                  |
| Podíl $\pi$           | $\hat{p} = x/n$                                               | <code>sum(x == k) / length(x)</code> |

### 5.3 Interval spolehlivosti a velikost výběru

#### 5.3.1 Interval pro průměr ( $\mu$ )

Odhadujeme skutečnou střední hodnotu populace  $\mu$  na základě výběrového průměru  $\bar{x}$ .

- **Neznámý  $\sigma^2$  (nebo  $n < 30$ ):**  $\bar{x} \pm t_{1-\alpha/2}(n-1) \cdot \frac{s}{\sqrt{n}}$
- **Známy  $\sigma^2$  (nebo  $n \geq 30$ ):**  $\bar{x} \pm z_{1-\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$

Pro **oboustranný** interval používáme kvantil  $1 - \alpha/2$ , pro **jednostranný**  $1 - \alpha$ .

**Implementace v R**

| Funkce                           | Příklad použití                                                                                                                                                           | Vysvětlení                                                                  |
|----------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------|
| <code>t.test(x)\$conf.int</code> | <pre>x &lt;- c(163,175,177,165,171,174) t.test(x, conf.level = 0.95) \$conf.int</pre>                                                                                     | Vrací 95% IS pro $\mu$ (neznámý $\sigma^2$ ).                               |
| Ručně<br>(t-rozdělení)           | <pre>xbar &lt;- mean(x); s &lt;- sd(x) n &lt;- length(x); alpha &lt;- 0.05 t_kr &lt;- qt(1 - alpha/2, df = n - 1) c(xbar - t_kr*s/sqrt(n),   xbar + t_kr*s/sqrt(n))</pre> | Ruční výpočet IS s t-rozdělením.                                            |
| Ručně (Z, známý $\sigma$ )       | <pre>sigma &lt;- 7 z_kr &lt;- qnorm(1 - alpha/2) c(xbar - z_kr*sigma/sqrt(n),   xbar + z_kr*sigma/sqrt(n))</pre>                                                          | Ruční výpočet IS s normálním rozdělením (velký výběr nebo známý $\sigma$ ). |

### Implementace v Python

| Funkce           | Příklad použití                                  | Vysvětlení                                                                                     |
|------------------|--------------------------------------------------|------------------------------------------------------------------------------------------------|
| Kritická hodnota | <pre>crit = t.ppf(1 - alpha/2, df=n-1)</pre>     | Kvantil pro t-interval (neznámé $\sigma$ ). Pro velké $n$ lze nahradit <code>norm.ppf</code> . |
| Mezní chyba      | <pre>err = crit * (s / np.sqrt(n))</pre>         | Výpočet odchylky; $s$ je výběrová směrodatná odchylka.                                         |
| Meze intervalu   | <pre>lower, upper = xbar - err, xbar + err</pre> | Parametr leží v intervalu s pravděpodobností $1 - \alpha$ .                                    |

### 5.3.2 Interval pro podíl ( $\pi$ )

Odhadujeme skutečný podíl  $\pi$  z výběrové relativní četnosti  $\hat{p} = x/n$ . Vždy použijeme normální rozdělení (Z-kvantil).

$$\hat{p} \pm z_{1-\alpha/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

### Implementace v R

| Funkce                                 | Příklad použití                                                                                                                                    | Vysvětlení                                   |
|----------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------|
| <code>prop.test(x, n)\$conf.int</code> | <pre>prop.test(x=110, n=200,   conf.level=0.95)\$conf.int</pre>                                                                                    | Wilsonův IS pro proporci (vestavěná funkce). |
| Ručně (Waldův IS)                      | <pre>x_vol &lt;- 110; n_vol &lt;- 200 p &lt;- x_vol / n_vol z_kr &lt;- qnorm(0.975) se &lt;- sqrt(p*(1-p)/n_vol) c(p - z_kr*se, p + z_kr*se)</pre> | Waldův IS – jednoduchá normální aproximace.  |

### Implementace v Python

| Funkce           | Příklad použití                                  | Vysvětlení                                                  |
|------------------|--------------------------------------------------|-------------------------------------------------------------|
| Kritická hodnota | <pre>z_crit = norm.ppf(1 - alpha / 2)</pre>      | Pro podíl se vždy používá normální rozdělení (Z-kvantil).   |
| Mezní chyba      | <pre>err = z_crit * np.sqrt(p * (1-p) / n)</pre> | Výpočet odchylky pro proporci $\hat{p}$ .                   |
| Meze intervalu   | <pre>lower, upper = p - err, p + err</pre>       | Parametr leží v intervalu s pravděpodobností $1 - \alpha$ . |

### 5.3.3 Potřebná velikost výběru ( $n$ )

Minimální rozsah výběru, aby se odhad nemýlil o více než  $\Delta$ . Výsledek **vždy zaokrouhlit nahoru**.

$$n \geq \left( \frac{z_{1-\alpha/2} \cdot \sigma}{\Delta} \right)^2 \quad (\text{průměr}), \quad n \geq \hat{p}(1 - \hat{p}) \cdot \left( \frac{z_{1-\alpha/2}}{\Delta} \right)^2 \quad (\text{podíl})$$

### Implementace v R

| Funkce                 | Příklad použití                                                                                                                                 | Vysvětlení                                                                       |
|------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------|
| Minimální $n$ (průměr) | <pre>alpha &lt;- 0.05; sigma &lt;- 10 delta &lt;- 2 # pozadovana presnost z_kr &lt;- qnorm(1 - alpha/2) ceiling((z_kr * sigma / delta)^2)</pre> | Pro průměr. $\Delta$ je cílová přesnost. Výsledek <b>vždy</b> zaokrouhli nahoru. |
| Minimální $n$ (podíl)  | <pre>p &lt;- 0.5; delta &lt;- 0.05 # +-5 p. b. ceiling(p*(1-p)*(z_kr/delta)^2)</pre>                                                            | Pro podíl. Používá se pro plánování reprezentativního výzkumu.                   |

### Implementace v Python

| Funkce                  | Příklad použití                                            | Vysvětlení                                                                       |
|-------------------------|------------------------------------------------------------|----------------------------------------------------------------------------------|
| Minimální n<br>(průměr) | <pre>n = math.ceil((z_crit * sigma /<br/>delta)**2)</pre>  | Pro průměr. $\Delta$ je cílová přesnost. Výsledek <b>vždy</b> zaokrouhli nahoru. |
| Minimální n<br>(podíl)  | <pre>n = math.ceil(p*(1-p) * (z_crit/<br/>delta)**2)</pre> | Pro podíl.                                                                       |

## 5.4 Jednovýběrový t-test (střední hodnota)

$H_0: \mu = \mu_0$ . Testové kritérium má t-rozdělení s  $n - 1$  stupni volnosti.

$$T = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \sim t(n - 1)$$

| Typ testu    | Alternativa $H_1$ | p-hodnota v R                           |
|--------------|-------------------|-----------------------------------------|
| Levostranný  | $\mu < \mu_0$     | <code>pt(T, df=n-1)</code>              |
| Pravostranný | $\mu > \mu_0$     | <code>1 - pt(T, df=n-1)</code>          |
| Oboustranný  | $\mu \neq \mu_0$  | <code>2*(1 - pt(abs(T), df=n-1))</code> |

### Implementace v R

| Funkce                                  | Příklad použití                                                                                                                                                                                             | Vysvětlení                                |
|-----------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------|
| <code>t.test(x,<br/>mu=mu0, ...)</code> | <pre>t.test(x, mu = 25000,<br/>       alternative = "less")<br/># "greater" / "two.sided"</pre>                                                                                                             | Automatický t-test z vektoru dat.         |
| Ručně                                   | <pre>n &lt;- 49; xbar &lt;- 23500; alpha &lt;-<br/>0.05<br/>mu0 &lt;- 25000; s &lt;- 5500<br/>T &lt;- (xbar - mu0)/(s/sqrt(n))<br/>p_val &lt;- pt(T, df = n - 1)<br/>t_kr &lt;- qt(alpha, df = n - 1)</pre> | Ruční výpočet (jednostranný levostranný). |

### Implementace v Python

| Funkce                                    | Příklad použití                                                                                                                                                                                  | Vysvětlení                                                                                                                                    |
|-------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------|
| <code>stats.ttest_1samp(data, mu0)</code> | <code>stats.ttest_1samp(data, popmean=mu0)</code>                                                                                                                                                | Porovnání průměru vzorku s pevnou hodnotou $\mu_0$ .                                                                                          |
| Ručně                                     | <pre>from scipy.stats import t as t_dist n=49; xbar=23500; s=5500 mu0=25000; alpha=0.05 T = (xbar - mu0) / (s / np.sqrt(n)) p_val = t_dist.cdf(T, df=n-1) t_kr = t_dist.ppf(alpha, df=n-1)</pre> | Ruční výpočet (jednostranný levostranný); pro pravostranný: <code>1-cdf(T,...)</code> ; pro oboustranný: <code>2*(1-cdf(abs(T),...))</code> . |

## 5.5 Dvouvýběrový t-test (Welchův)

$H_0: \mu_1 = \mu_2$ . Welchova aproximace stupňů volnosti (předpokládáme různé rozptyly).

$$T = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$$

### Implementace v R

| Funkce                                       | Příklad použití                                                                                                                                                                                                                                 | Vysvětlení                                                              |
|----------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------|
| <code>t.test(x1, x2, var.equal=FALSE)</code> | <code>t.test(x1, x2, var.equal = FALSE, alternative = "two.sided")</code>                                                                                                                                                                       | Welchův test (různé rozptyly).                                          |
| Ručně (ze souhrnných statistik)              | <pre>n1&lt;-38; x1&lt;-5.3875; s1_2&lt;-0.2698 n2&lt;-35; x2&lt;-4.7; s2_2&lt;-0.24 T &lt;- (x1-x2)/sqrt(s1_2/n1+s2_2/n2) df_w &lt;- (s1_2/n1+s2_2/n2)^2 / ((s1_2/n1)^2/(n1-1)+ (s2_2/n2)^2/(n2-1)) p_val &lt;- 2*(1-pt(abs(T), df=df_w))</pre> | Welch-Satterthwaiteovy stupně volnosti ( $s_1^2, s_2^2$ jsou rozptyly). |

### Implementace v Python

| Funkce                             | Příklad použití                                     | Vysvětlení                                                |
|------------------------------------|-----------------------------------------------------|-----------------------------------------------------------|
| <code>stats.ttest_ind(A, B)</code> | <code>stats.ttest_ind(A, B, equal_var=False)</code> | Porovnání průměrů dvou nezávislých skupin (Welchův test). |

## 5.6 Párový t-test

$H_0: \mu_d = 0$ , kde  $d_i = x_{2i} - x_{1i}$  jsou párové rozdíly. Aplikuje jednovýběrový t-test na rozdíly.



## Implementace v R

| Funkce                                     | Příklad použití                                                                       | Vysvětlení                                                                   |
|--------------------------------------------|---------------------------------------------------------------------------------------|------------------------------------------------------------------------------|
| <code>t.test(pred, po, paired=TRUE)</code> | <pre>t.test(pred, po,         paired = TRUE,         alternative = "two.sided")</pre> | Porovnání stejné skupiny ve dvou různých situacích (např. před a po zásahu). |

## Implementace v Python

| Funkce                                 | Příklad použití                      | Vysvětlení                                          |
|----------------------------------------|--------------------------------------|-----------------------------------------------------|
| <code>stats.ttest_rel(po, pred)</code> | <pre>stats.ttest_rel(po, pred)</pre> | Porovnání stejné skupiny ve dvou různých situacích. |

## 5.7 Test proporce (Z-test)

$H_0: \pi = \pi_0$ . Testové kritérium:

$$Z = \frac{\hat{p} - \pi_0}{\sqrt{\pi_0(1 - \pi_0)/n}} \sim N(0, 1)$$

## Implementace v R

| Funkce                                  | Příklad použití                                                                                                                                                          | Vysvětlení                                             |
|-----------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------|
| <code>prop.test(x, n, p=p0, ...)</code> | <pre>prop.test(x=90, n=150, p=0.5,         alternative="two.sided",         correct=FALSE)</pre>                                                                         | Bez Yatesovy korekce odpovídá ručnímu Z-testu.         |
| Ručně                                   | <pre>p0 &lt;- 0.5; n &lt;- 150; orel &lt;- 90 phat &lt;- orel/n Z &lt;- (phat-p0)/sqrt(p0*(1-p0)/n) z_kr &lt;- qnorm(1 - 0.01/2) p_val &lt;- 2*(1 - pnorm(abs(Z)))</pre> | Oboustranný Z-test symetrie mince ( $\alpha = 0,01$ ). |

## Implementace v Python

| Funkce                         | Příklad použití                                                                                                                                                                                        | Vysvětlení                                                                                                                              |
|--------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------|
| <code>proportions_ztest</code> | <pre>from statsmodels.stats.     proportion import     proportions_ztest z_stat, p_val =     proportions_ztest(         count=90, nobs=150,         value=0.5, alternative='two-         sided')</pre> | Z-test proporce. <code>count</code> = počet úspěchů, <code>nobs</code> = rozsah výběru, <code>value</code> = $\pi_0$ . Vrací $(Z, p)$ . |

## 5.8 Jednocestná analýza rozptylu (ANOVA)

$H_0$ :  $\mu_1 = \mu_2 = \dots = \mu_k$ ,  $H_1$ : alespoň dva průměry se liší.

Test je vždy **pravostranný**: zamítáme  $H_0$ , pokud  $F \geq F_{1-\alpha}(k-1, n-k)$ .

$$F = \frac{S_m/(k-1)}{S_v/(n-k)} \sim F(k-1, n-k), \quad S_m = \sum_{j=1}^k n_j(\bar{x}_j - \bar{x})^2, \quad S_v = \sum_{j=1}^k \sum_{i=1}^{n_j} (x_{ij} - \bar{x}_j)^2$$

### Implementace v R

| Funkce                        | Příklad použití                                                                                                                                                                                                           | Vysvětlení                                                   |
|-------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------|
| <code>aov(y ~ skupina)</code> | <pre>y &lt;- c(91,81,74,57, 83,72,63,47,        71,69,58,40) skupina &lt;- factor(rep(c("A","B",                         "","C"),                       each=4)) m &lt;- aov(y ~ skupina) summary(m)</pre>                | Automatická ANOVA s tabulkou výsledků.                       |
| Skupinové průměry             | <code>tapply(y, skupina, mean)</code>                                                                                                                                                                                     | Průměry v každé skupině.                                     |
| Kritická hodnota F            | <pre>k &lt;- nlevels(skupina); n &lt;- length(y) qf(0.95, df1 = k-1, df2 = n-k)</pre>                                                                                                                                     | Kvantil F-rozdělení pro $\alpha = 0,05$ .                    |
| Ručně (SS)                    | <pre>grand &lt;- mean(y) SS_m &lt;- sum(tapapply(y,skupina, function(g) length(g)*(mean(g)- grand)^2)) SS_v &lt;- sum(tapapply(y,skupina, function(g) sum((g-mean(g))^2)) ) F_stat &lt;- (SS_m/(k-1))/(SS_v/(n- k))</pre> | Ruční výpočet součtů čtverců mezi skupinami a uvnitř skupin. |

### Implementace v Python

| Funkce                               | Příklad použití                      | Vysvětlení                                   |
|--------------------------------------|--------------------------------------|----------------------------------------------|
| <code>stats.f_oneway(A, B, C)</code> | <code>stats.f_oneway(A, B, C)</code> | Testování shody průměrů u tří a více skupin. |

## 5.9 Chí-kvadrát test dobré shody

$H_0$ : výběr odpovídá předpokládanému rozdělení.

$$G = \sum_j \frac{(n_j - e_j)^2}{e_j} \sim \chi^2(k-1), \quad e_j = n \cdot \pi_{0,j}$$

## Implementace v R

| Funkce                                 | Příklad použití                                                                                                                                                                                       | Vysvětlení                                                              |
|----------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------|
| <code>chisq.test(emp, p=p_teor)</code> | <pre>emp &lt;- c(A=82, B=38, AB=26, 0         =69) p0 &lt;- c(A=0.41, B=0.14, AB=0.07, 0         =0.38) chisq.test(emp, p = p0)</pre>                                                                 | Automatický test dobré shody. Vektor <code>p0</code> musí mít součet 1. |
| Ručně                                  | <pre>teor &lt;- sum(emp) * p0 G &lt;- sum((emp - teor)^2 / teor) p_val &lt;- 1 - pchisq(G, df=length                     (emp)-1) chi_kr &lt;- qchisq(0.99, df=length                  (emp)-1)</pre> | Ruční výpočet testové statistiky a p-hodnoty.                           |

## Implementace v Python

| Funkce                                   | Příklad použití                          | Vysvětlení                                                                           |
|------------------------------------------|------------------------------------------|--------------------------------------------------------------------------------------|
| <code>stats.chisquare(O, f_exp=E)</code> | <code>stats.chisquare(O, f_exp=E)</code> | Test dobré shody. <code>O</code> jsou pozorované, <code>E</code> očekávané četnosti. |

### 5.10 Chí-kvadrát test nezávislosti

**H<sub>0</sub>:** řádkový a sloupcový znak jsou nezávislé. Kontingenční tabulka  $r \times s$ :  $n_{i.} = \sum_j n_{ij}$  (řádkové součty),  $n_{.j} = \sum_i n_{ij}$  (sloupcové součty).

$$n'_{ij} = \frac{n_{i.} n_{.j}}{n}, \quad n'_{ij} \geq 5, \quad G = \sum_{i=1}^r \sum_{j=1}^s \frac{(n_{ij} - n'_{ij})^2}{n'_{ij}} \sim \chi^2((r-1)(s-1))$$

Pro tabulku  $2 \times 2$ :

$$G = \frac{n(n_{11}n_{22} - n_{12}n_{21})^2}{n_{1.}n_{2.}n_{.1}n_{.2}}$$

Síla závislosti: Pearsonovo  $C = \sqrt{\frac{G}{n+G}}$ ; Cramérovo  $V = \sqrt{\frac{G}{n(\min(r, s) - 1)}} \in [0, 1]$ , kde  $m = \min(r, s)$ .

Interpretace  $V$ :  $< 0,1$  zanedbatelná ·  $0,1-0,3$  slabá ·  $0,3-0,5$  středně silná ·  $> 0,5$  silná.

## Implementace v R

| Funkce                           | Příklad použití                                                                                                                                                                                                                                    | Vysvětlení                                                                     |
|----------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------|
| <code>chisq.test(tabulka)</code> | <pre> kt &lt;- matrix(c(1768,807,189,47,                946,1387,746,53,                115,438,288,16),              nrow=3, byrow=TRUE) res &lt;- chisq.test(kt) res\$p.value # p-hodnota res\$expected # teoretické             cetnosti </pre> | Test nezávislosti z kontingenční tabulky.                                      |
| Cramérovo $V$                    | <pre> G &lt;- as.numeric(res\$statistic) n_celk &lt;- sum(kt) r &lt;- nrow(kt); s_kt &lt;- ncol(kt) V &lt;- sqrt(G / (n_celk*(min(r,                            s_kt)-1))) C &lt;- sqrt(G / (G + n_celk)) </pre>                                   | Síla závislosti: $V \in [0,1]$ .<br>Pearsonův $C$ závisí na rozměrech tabulky. |

### Implementace v Python

| Funkce                                    | Příklad použití                                                | Vysvětlení                                         |
|-------------------------------------------|----------------------------------------------------------------|----------------------------------------------------|
| <code>stats.chi2_contingency(tabl)</code> | <pre> chi2, p, df, exp = stats. chi2_contingency(table) </pre> | Vrací<br>( $\chi^2, p, df$ , teoretické četnosti). |

## 5.11 Stupně volnosti – přehled

**Zlaté pravidlo:** stupně volnosti = počet pozorování – počet odhadovaných parametrů.

### T-testy

| Test                                 | df                         | Poznámka                         |
|--------------------------------------|----------------------------|----------------------------------|
| Jednovýběrový t-test                 | $df = n - 1$               | $n$ = počet pozorování           |
| Párový t-test                        | $df = n_{\text{párů}} - 1$ | $n$ = počet párů                 |
| Dvouvýběrový t-test (shoda rozptylů) | $df = n + m - 2$           | $n, m$ = velikosti skupin        |
| Dvouvýběrový t-test (Welchův)        | $df \approx \text{Welch}$  | složitý vzorec – spočítá program |

### F-testy

| Test                | $df_1$  | $df_2$  | Poznámka                        |
|---------------------|---------|---------|---------------------------------|
| Test shody rozptylů | $n - 1$ | $m - 1$ | dva df – jeden pro každý soubor |
| ANOVA (F-test)      | $k - 1$ | $n - k$ | $k$ = počet skupin              |

### Chí-kvadrát testy

| Test                                 | df                                              |
|--------------------------------------|-------------------------------------------------|
| Test dobré shody                     | $df = k - 1$ ( $k$ = počet kategorií)           |
| Test nezávislosti (konting. tabulka) | $df = (r - 1)(s - 1)$ ( $r$ řádků, $s$ sloupců) |

## 6 Analýza závislosti

### 6.1 Korelační analýza

#### 6.1.1 Pearsonův korelační koeficient

Měří sílu **lineární** závislosti dvou spojitých proměnných.

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}}, \quad r \in [-1, 1]$$

Test  $H_0: \rho = 0$ :  $T = r\sqrt{(n-2)/(1-r^2)} \sim t(n-2)$ .

Interpretace  $|r|$ :  $< 0,3$  slabá  $\cdot$   $0,3-0,7$  střední  $\cdot$   $> 0,7$  silná závislost. Znaménko udává směr.

#### Implementace v R

| Funkce                                   | Příklad použití                                                                                        | Vysvětlení                                                       |
|------------------------------------------|--------------------------------------------------------------------------------------------------------|------------------------------------------------------------------|
| <code>cor(x, y, method="pearson")</code> | <pre>x &lt;- c(1,2,0,5,3,4,2,6,1,3) y &lt;- c(0,1,0,4,2,3,1,5,0,2) cor(x, y, method = "pearson")</pre> | Hodnota korelačního koeficientu $r \in [-1, 1]$ .                |
| <code>cor.test(x, y)</code>              | <pre>cor.test(x, y, method = "pearson")</pre>                                                          | Test $H_0: \rho = 0$ ; vrací $p$ -hodnotu, $T$ a IS pro $\rho$ . |

#### Implementace v Python

| Funkce                            | Příklad použití                        | Vysvětlení                                                            |
|-----------------------------------|----------------------------------------|-----------------------------------------------------------------------|
| <code>stats.pearsonr(x, y)</code> | <pre>r, p = stats.pearsonr(x, y)</pre> | Vrací korelační koeficient $r$ a $p$ -hodnotu testu $H_0: \rho = 0$ . |

#### 6.1.2 Spearmanův korelační koeficient

Měří sílu **monotónní** závislosti (neparametrický, odolný vůči odlehlým hodnotám). Počítá se jako Pearsonův koeficient aplikovaný na pořadí hodnot.

#### Implementace v R

| Funkce                                         | Příklad použití                                | Vysvětlení                                                         |
|------------------------------------------------|------------------------------------------------|--------------------------------------------------------------------|
| <code>cor(x, y, method="spearman")</code>      | <pre>cor(x, y, method = "spearman")</pre>      | Hodnota Spearmanova koeficientu $r_s$ .                            |
| <code>cor.test(x, y, method="spearman")</code> | <pre>cor.test(x, y, method = "spearman")</pre> | Test $H_0: \rho_s = 0$ ; vrací $p$ -hodnotu a testovou statistiku. |

#### Implementace v Python

| Funkce                             | Příklad použití                           | Vysvětlení                                                      |
|------------------------------------|-------------------------------------------|-----------------------------------------------------------------|
| <code>stats.spearmanr(x, y)</code> | <pre>rho, p = stats.spearmanr(x, y)</pre> | Vrací Spearmanův $r_s$ a $p$ -hodnotu testu $H_0: \rho_s = 0$ . |

## 6.2 Jednoduchá lineární regrese

### 6.2.1 Odhad koeficientů (MNČ)

Model:  $\hat{y} = b_0 + b_1x$ . Koeficienty minimalizují součet čtverců reziduí  $Q = \sum e_i^2$ .

$$b_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad b_0 = \bar{y} - b_1\bar{x}$$

#### Implementace v R

| Funkce                 | Příklad použití                                                                                                                                 | Vysvětlení                                                                                           |
|------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------|
| <code>lm(y ~ x)</code> | <pre>m &lt;- lm(cena ~ naklady) summary(m) # koef., R^2, testy coef(m) # b0 a b1 fitted(m) # vyrovnané hodnoty residuals(m) # rezidua e_i</pre> | Fituje lineární model; <code>summary</code> vrací koeficienty, $R^2$ , t-testy i F-test automaticky. |
| Koeficienty<br>ručně   | <pre>x_b &lt;- mean(x); y_b &lt;- mean(y) b1 &lt;- sum((x-x_b)*(y-y_b)) /       sum((x-x_b)^2) b0 &lt;- y_b - b1 * x_b</pre>                    | Ruční výpočet metodou nejmenších čtverců (minimalizace $Q = \sum e_i^2$ ).                           |

#### Implementace v Python

| Funkce                              | Příklad použití                                                                                                                                                                   | Vysvětlení                                                                                                                                               |
|-------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------|
| <code>stats.linregress(x, y)</code> | <pre>res = stats.linregress(x, y)</pre>                                                                                                                                           | Vrací <code>slope</code> ( $b_1$ ), <code>intercept</code> ( $b_0$ ), <code>r</code> , <code>p</code> -hodnotu a <code>stderr</code> (základní regrese). |
| <code>smf.ols(f, data)</code>       | <pre>import statsmodels.formula.api as smf m = smf.ols('y ~ x', data=df).fit() print(m.summary()) # Komplexní výstup</pre>                                                        | Fituje model pomocí vzorce (stejná syntaxe jako R). Funkce <code>summary()</code> vrací koeficienty, $R^2$ , i testy.                                    |
| Vícenásobná<br>regrese              | <pre># Model s více prediktory m2 = smf.ols('y ~ x1 + x2 + x3',              data=df).fit() print(m2.summary())  # Upravený R^2 pro porovnání modelu print(m2.rsquared_adj)</pre> | <code>summary()</code> vypíše tabulku, kde <b>Adj. R-squared</b> použijeme k porovnání s jednodušším modelem (penalizuje za zbytečné parametry).         |

### 6.2.2 Součty čtverců a koeficient determinace $R^2$

$$S_Y = S_T + S_R, \quad R^2 = \frac{S_T}{S_Y} \in [0, 1], \quad R_{ADJ}^2 = 1 - (1 - R^2) \frac{n-1}{n-p}$$

kde  $S_Y = \sum (y_i - \bar{y})^2$  (celkový),  $S_T = \sum (\hat{y}_i - \bar{y})^2$  (teoretický),  $S_R = \sum (y_i - \hat{y}_i)^2$  (reziduální),  $p$  = počet odhadovaných parametrů (pro jednoduchou regresi  $p = 2$ ).

### Implementace v R

| Funkce                    | Příklad použití                                                                                                                                                                | Vysvětlení                                                                   |
|---------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------|
| Součty čtverců<br>a $R^2$ | <pre>SS_tot &lt;- sum((y - mean(y))^2) SS_reg &lt;- sum((fitted(m)-mean(y))^2) SS_res &lt;- sum(residuals(m)^2) R2 &lt;- SS_reg / SS_tot summary(m)\$r.squared # zkratka</pre> | $S_Y = S_T + S_R$ ; $R^2 = S_T/S_Y$ – podíl rozptylu $Y$ vysvětlený modelem. |

### Implementace v Python

| Funkce    | Příklad použití                      | Vysvětlení                                                                     |
|-----------|--------------------------------------|--------------------------------------------------------------------------------|
| r_squared | <pre>r_squared = res.rvalue**2</pre> | $R^2$ jako čtverec korelačního koeficientu (z <code>stats.linregress</code> ). |

### 6.2.3 t-test a F-test platnosti modelu

**t-test pro  $b_1$ :**  $H_0: \beta_1 = 0$ ;  $T = b_1/s_{b_1} \sim t(n-2)$ .

**F-test modelu:**  $H_0: \beta_1 = 0$ ;  $F = S_T/(S_R/(n-2)) \sim F(1; n-2)$ .

### Implementace v R

| Funkce           | Příklad použití                                                                                                                                                                                                            | Vysvětlení                                                                         |
|------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------|
| t-test pro $b_1$ | <pre>n &lt;- length(x) se_b1 &lt;- sqrt(SS_res/(n-2) /               sum((x-mean(x))^2)) t_stat &lt;- b1 / se_b1 qt(0.975, df=n-2) # krit.               hodnota 2*(1-pt(abs(t_stat), df=n-2)) #               p-val</pre> | $H_0: \beta_1 = 0$ ; zamítáme při $ T  \geq t_{1-\alpha/2}(n-2)$ .                 |
| F-test modelu    | <pre>F_stat &lt;- (SS_reg/1)/(SS_res/(n-2)) qf(0.95, df1=1, df2=n-2)</pre>                                                                                                                                                 | Pro jednoduchou regresi ekvivalentní t-testu. Výsledek v <code>summary(m)</code> . |

### Implementace v Python

| Funkce              | Příklad použití       | Vysvětlení                                                             |
|---------------------|-----------------------|------------------------------------------------------------------------|
| p-hodnota pro $b_1$ | <pre>res.pvalue</pre> | p-hodnota testu $H_0: \beta_1 = 0$ (z <code>stats.linregress</code> ). |

### 6.2.4 Predikce

Bodová predikce střední hodnoty  $Y$  pro novou hodnotu  $x^*$ :  $\hat{y}^* = b_0 + b_1 x^*$ .

#### Implementace v R

| Funkce                                   | Příklad použití                                                                                                                                 | Vysvětlení                                                          |
|------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------|
| <code>predict(m,<br/>newdata=...)</code> | <pre>predict(m, newdata=data.frame(<br/>  naklady=80))<br/>predict(m, newdata=data.frame(<br/>  naklady=80),<br/>  interval="confidence")</pre> | Bodová predikce i IS pro střední hodnotu $Y$ při nové hodnotě $X$ . |

#### Implementace v Python

| Funkce                    | Příklad použití                                                                                          | Vysvětlení                                                                                       |
|---------------------------|----------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------|
| Predikce<br>(scipy)       | <pre>y_hat = res.intercept + res.<br/>  slope * x_new</pre>                                              | Bodová predikce ručně z výsledků <code>stats.linregress</code> .                                 |
| Predikce<br>(statsmodels) | <pre>pred = m.get_prediction(<br/>  nove_data)<br/>pred.summary_frame() # Obsahuje<br/>  intervaly</pre> | Vrátí <code>DataFrame</code> obsahující bodovou predikci i interval spolehlivosti pro nová data. |



## 7 Časové řady

### 7.1 Základní charakteristiky

#### 7.1.1 Absolutní přírůstky a tempa růstu

$$1. \text{ difference: } \Delta y_t = y_t - y_{t-1}$$

$$\text{Průměrná 1. difference: } \bar{\Delta} = \frac{1}{n-1} \sum_{t=2}^n \Delta_t = \frac{y_n - y_1}{n-1}$$

$$\text{Tempo růstu: } k_t = y_t / y_{t-1}$$

$$\text{Průměrné tempo: } \bar{k} = \sqrt[n-1]{y_n / y_1}$$

#### Implementace v R

| Funkce               | Příklad použití                                                                                               | Vysvětlení                                                           |
|----------------------|---------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------|
| <code>diff(y)</code> | <pre>y &lt;- c   (5274,5288,5297,5318,5338,5356)  diff(y) # 1. difference diff(diff(y)) # 2. difference</pre> | Absolutní přírůstky první a druhé řádu.                              |
| Tempo růstu          | <pre>n &lt;- length(y) tempo &lt;- y[-1] / y[-n] prum_tempo &lt;- (y[n]/y[1])^(1/(n-1))</pre>                 | Mezičasové indexy $k_t$ a průměrné tempo růstu (geometrický průměr). |

#### Implementace v Python

| Funkce                  | Příklad použití             | Vysvětlení                                              |
|-------------------------|-----------------------------|---------------------------------------------------------|
| <code>np.diff(y)</code> | <code>np.diff(y)</code>     | Absolutní přírůstky (1. difference).                    |
| Tempo růstu             | <code>y[1:] / y[:-1]</code> | Mezičasové indexy $k_t$ pro NumPy pole <code>y</code> . |

#### 7.1.2 Chronologický průměr

Pro okamžikovou časovou řadu (stejně dlouhé intervaly – nevážený):

$$\bar{y} = \frac{\frac{1}{2}y_1 + y_2 + \dots + y_{n-1} + \frac{1}{2}y_n}{n-1}$$

Pro nestejně dlouhé intervaly (vážený chronologický průměr, délky intervalů  $d_1, \dots, d_{n-1}$ ):

$$\bar{y} = \frac{\frac{y_1 + y_2}{2}d_1 + \frac{y_2 + y_3}{2}d_2 + \dots + \frac{y_{n-1} + y_n}{2}d_{n-1}}{d_1 + d_2 + \dots + d_{n-1}}$$

## Implementace v R

| Funkce               | Příklad použití                                                           | Vysvětlení                                                              |
|----------------------|---------------------------------------------------------------------------|-------------------------------------------------------------------------|
| Chronologický průměr | <pre>n &lt;- length(y) (y[1]/2 + sum(y[2:(n-1)]) +  y[n]/2) / (n-1)</pre> | Průměr okamžikové časové řady; krajní hodnoty mají váhu $\frac{1}{2}$ . |

## Implementace v Python

| Funkce               | Příklad použití                                                | Vysvětlení                     |
|----------------------|----------------------------------------------------------------|--------------------------------|
| Chronologický průměr | <pre>(y[0]/2 + np.sum(y[1:-1]) + y  [-1]/2) / (len(y)-1)</pre> | Průměr okamžikové časové řady. |

## 7.2 Řetězové a bazické indexy

**Řetězový index** (mezičasový): poměr k předchozímu období. **Bazický index**: poměr k základnímu období (období 1).

$$k_t = I_{t/t-1} = \frac{y_t}{y_{t-1}}$$

$$\bar{k} = \sqrt[n-1]{k_2 k_3 \cdots k_n} = \sqrt[n-1]{\frac{y_n}{y_1}}$$

$$I_{t/1} = I_{2/1} \cdot I_{3/2} \cdots I_{t/t-1}$$

$$I_{k/t-1} = \frac{y_t}{y_{t-1}} = \frac{I_{t/1}}{I_{(t-1)/1}}$$

## 7.3 Klouzavé průměry

### 7.3.1 Prostý klouzavý průměr (liché $m$ )

Symetrické okno šířky  $m = 2p + 1$ :  $\tilde{y}_t = \frac{1}{m} \sum_{j=-p}^p y_{t+j}$ . Odstraňuje sezónnost délky  $\leq m$ .

## Implementace v R

| Funkce                 | Příklad použití                                                                      | Vysvětlení                                         |
|------------------------|--------------------------------------------------------------------------------------|----------------------------------------------------|
| filter(y, rep(1/m, m)) | <pre>m &lt;- 5 # liche m -- prosty KP kp &lt;- filter(y, rep(1/m,m),  sides=2)</pre> | Prostý klouzavý průměr; sides=2 = symetrické okno. |

## Implementace v Python

| Funkce      | Příklad použití                                        | Vysvětlení                                      |
|-------------|--------------------------------------------------------|-------------------------------------------------|
| np.convolve | <pre>np.convolve(y, np.ones(m)/m,  mode='valid')</pre> | Prostý klouzavý průměr (ztratí krajní hodnoty). |

### 7.3.2 Centrovaný klouzavý průměr (sudé $m$ )

Pro sudé  $m$ : centrovaný KP = průměr dvou po sobě jdoucích prostých KP délky  $m$ . Používá se pro čtvrtletní nebo měsíční data.

$$\bar{y}_t = \frac{y_{t-p} + 2y_{t-p+1} + \dots + 2y_t + \dots + 2y_{t+p-1} + y_{t+p}}{2m}, \quad m = 2p$$

#### Implementace v R

| Funkce                       | Příklad použití                                                                                              | Vysvětlení                                                                                                                                     |
|------------------------------|--------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------|
| Centrovaný KP<br>(sudé $m$ ) | <pre>m &lt;- 4 # sude m -- centrovaný KP kp_c &lt;- filter(y,   c(0.5, rep(1, m-1), 0.5)/m,   sides=2)</pre> | Váhy<br>$c(0.5, 1, \dots, 1, 0.5)/m$<br>odpovídají vzorci; <code>sides=2</code><br>= symetrické okno, výsledek<br>je správně zarovnán na $t$ . |

#### Implementace v Python

| Funkce        | Příklad použití                                                                                                                           | Vysvětlení                                                                                                                                                |
|---------------|-------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------|
| Centrovaný KP | <pre># Pro m=4 (čtvrtletní data) m = 4 w = np.array([0.5] + [1]*(m-1) +   [0.5]) / m kp_c = np.convolve(y, w[::-1],   mode='valid')</pre> | Váhy<br>$[0.5, 1, \dots, 1, 0.5]/m$<br>odpovídají vzorci;<br><code>mode='valid'</code> ořízne<br>krajní hodnoty stejně<br>jako <code>filter()</code> v R. |

## 7.4 Trend a sezónnost – regresní přístup

### 7.4.1 Dummy proměnné a model

Model:  $y_t = \beta_0 + \beta_1 t + \gamma_1 D_1 + \gamma_2 D_2 + \gamma_3 D_3 + \varepsilon_t$  (sezónnost délky 4;  $D_j$  jsou dummy proměnné; 4. čtvrtletí je referenční kategorie).

#### Implementace v R

| Funkce                         | Příklad použití                                                                                                                                                    | Vysvětlení                                                                                                                |
|--------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------|
| Dummy proměnné                 | <pre>t &lt;- 1:length(y) Q2 &lt;- as.integer(t %% 4 == 2) Q3 &lt;- as.integer(t %% 4 == 3) Q4 &lt;- as.integer(t %% 4 == 0) # Q1 je referenční (t %% 4 == 1)</pre> | Vždy o jednu méně dummy<br>než sezón – jinak hrozí mul-<br>tikolinearita.                                                 |
| lm() s trendem<br>a sezónností | <pre>m &lt;- lm(y ~ t + Q2 + Q3 + Q4) summary(m) fitted(m) # vyrovnané hodnoty</pre>                                                                               | Odhaduje lineární trend a<br>sezónní odchylky; $\hat{\gamma}_j$ = od-<br>chylka $j$ -tého čtvrtletí od re-<br>ferenčního. |

#### Implementace v Python

| Funkce                              | Příklad použití                                                                                                                                                                                                                                         | Vysvětlení                                                                                                   |
|-------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------|
| Dummy proměnné                      | <pre>import numpy as np t = np.arange(1, len(y)+1) Q2 = (t % 4 == 2).astype(int) Q3 = (t % 4 == 3).astype(int) Q4 = (t % 4 == 0).astype(int) # Q1 je referencni (t % 4 == 1)</pre>                                                                      | Vždy o jednu méně dummy než sezón – jinak hrozí multikolinearita.                                            |
| smf.ols()<br>s trendem a sezónností | <pre>import pandas as pd import statsmodels.formula.api as smf df = pd.DataFrame(     {'y':y,'t':t,'Q2':Q2,'Q3':Q3,'Q4':Q4}) m = smf.ols('y ~ t + Q2 + Q3 + Q4',             data=df).fit() print(m.summary()) m.fittedvalues # vyrovnané hodnoty</pre> | Odhaduje lineární trend a sezónní odchylky; $\hat{\gamma}_j$ = odchylka $j$ -tého čtvrtletí od referenčního. |

## 7.4.2 Dekompozice časové řady

Rozklad časové řady na trend  $T_t$ , sezónní  $S_t$ , cyklickou  $C_t$  a reziduální složku  $\varepsilon_t$ :

$$y_t = T_t + S_t + C_t + \varepsilon_t \quad (\text{aditivní model}) \qquad y_t = T_t \cdot S_t \cdot C_t \cdot \varepsilon_t \quad (\text{multiplikativní model})$$

Rezidua a kvalita modelu (trend  $\hat{y}_t$ , MSE, Durbin-Watson  $D$ ):

$$e_t = y_t - \hat{y}_t, \quad MSE = \frac{\sum_{t=1}^n e_t^2}{n}, \quad D = \frac{\sum_{t=2}^n (e_t - e_{t-1})^2}{\sum_{t=1}^n e_t^2}$$

Sezónní složky (regresní přístup, sezónnost délky 4;  $a_i$  jsou odhadnuté koeficienty dummy proměnných):

$$\bar{a} = \frac{a_1 + a_2 + a_3}{4}, \quad S_{i+4j} = a_i - \bar{a} \quad (i = 1, 2, 3), \quad S_{4+4j} = -\bar{a}$$

## Implementace v Python

| Funkce             | Příklad použití                                                                                                                                   | Vysvětlení                                                                                    |
|--------------------|---------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------|
| seasonal_decompose | <pre>from statsmodels.tsa.seasonal import seasonal_decompose decomp = seasonal_decompose(df['y'], model='additive', period=4) decomp.plot()</pre> | Automatický rozklad řady na komponenty. Vykreslí originální data, trend, sezónnost a rezidua. |

| Funkce                      | Příklad použití                                           | Vysvětlení                                                   |
|-----------------------------|-----------------------------------------------------------|--------------------------------------------------------------|
| <code>pd.get_dummies</code> | <pre>pd.get_dummies(df['quarter'], drop_first=True)</pre> | Automatické dummy proměnné z kategorického sloupce (pandas). |

### 7.4.3 Predikce na budoucí období

Sestavíme `data.frame` s  $t$  a dummy proměnnými pro každé nové pozorování.

#### Implementace v R

| Funkce                               | Příklad použití                                                                                                                                                                           | Vysvětlení                    |
|--------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------|
| <code>predict(m, newdata=...)</code> | <pre>t_n &lt;- 21:24 nd &lt;- data.frame(   t = t_n,   Q2 = as.integer(t_n %% 4 == 2),   Q3 = as.integer(t_n %% 4 == 3),   Q4 = as.integer(t_n %% 4 == 0)) predict(m, newdata = nd)</pre> | Predikce na budoucí kvartály. |

#### Implementace v Python

| Funkce                            | Příklad použití                 | Vysvětlení                                             |
|-----------------------------------|---------------------------------|--------------------------------------------------------|
| <code>model.predict(X_new)</code> | <pre>model.predict(X_new)</pre> | Predikce na nová data (scikit-learn nebo statsmodels). |

## 7.5 Nelineární trendy časových řad

### 7.5.1 Kvadratický (parabolický) trend

Model:  $\hat{T}_t = b_0 + b_1 t + b_2 t^2$ , kde  $t = 1, 2, \dots, n$  je časová proměnná.

Znaménko  $b_2$  určuje tvar paraboly:  $b_2 > 0$  – konvexní (tvar U, minimum),  $b_2 < 0$  – konkávní (tvar  $\cap$ , maximum).

#### Implementace v R

| Funkce            | Příklad použití                                                                                                      | Vysvětlení                                                                                                                                                                                                             |
|-------------------|----------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Kvadratický trend | <pre>t &lt;- 1:length(y) m &lt;- lm(y ~ t + I(t^2)) summary(m) # b0, b1, b2, R^2 fitted(m) # vyrovnané hodnoty</pre> | Funkce <code>I(t^2)</code> izoluje mocninu od vzorcové syntaxe. Koeficienty v <code>Estimate:</code> <code>(Intercept) = b<sub>0</sub></code> , <code>t = b<sub>1</sub></code> , <code>I(t^2) = b<sub>2</sub></code> . |
| Predikce          | <pre># Predikce pro t = 11 (rok 2018) predict(m, newdata = data.frame(   t = 11))</pre>                              | Dosadí $t = 11$ do odhadnutého modelu $\hat{T}_{11} = b_0 + b_1 \cdot 11 + b_2 \cdot 121$ .                                                                                                                            |

## Implementace v Python

| Funkce            | Příklad použití                                                                                                                                                                                   | Vysvětlení                                                                                                           |
|-------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------|
| Kvadratický trend | <pre>import numpy as np import statsmodels.formula.api     as smf t = np.arange(1, len(y) + 1) df['t'] = t df['t2'] = t**2 m = smf.ols('y ~ t + t2', data=     df).fit() print(m.summary())</pre> | Kvadratický člen se přidá jako nový sloupec <code>t2</code> ; <code>summary()</code> vrátí $b_0, b_1, b_2$ a $R^2$ . |

### 7.5.2 Exponenciální trend

Vhodný tehdy, kdy časová řada roste (nebo klesá) relativně konstantním tempem.

Model v logaritmické linearizaci:

$$y_t = b_0 \cdot b_1^t \implies \ln y_t = \ln b_0 + t \cdot \ln b_1 \implies y^* = \beta_0^* + \beta_1^* t$$

kde  $y^* = \ln y_t$ ,  $\beta_0^* = \ln b_0$ ,  $\beta_1^* = \ln b_1$ . Zpětná transformace:  $b_0 = e^{\beta_0^*}$ ,  $b_1 = e^{\beta_1^*}$ . Tempo růstu:  $(b_1 - 1) \times 100\%$  za jednu časovou jednotku.

## Implementace v R

| Funkce                 | Příklad použití                                                                                                                                                                     | Vysvětlení                                                                                             |
|------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------|
| Exponenciální trend    | <pre>t &lt;- 1:length(y) m_exp &lt;- lm(log(y) ~ t) summary(m_exp) # beta0*, beta1* # Zpetna transformace b0 &lt;- exp(coef(m_exp)[1]) # b0 b1 &lt;- exp(coef(m_exp)[2]) # b1</pre> | Regrese probíhá na $\ln y$ ; výsledné koeficienty je nutné zpětně transformovat pomocí $e^{(\cdot)}$ . |
| Predikce (orig. škála) | <pre># Predikce pro t = 11 y_hat_log &lt;- predict(m_exp,     newdata = data.frame(t = 11)) exp(y_hat_log) # zpet na puvodni     skalu</pre>                                        | <code>predict</code> vrací hodnotu na logaritmické škále; <code>exp()</code> převede zpět na původní.  |

## Implementace v Python

| Funkce              | Příklad použití                                                                                                                                                                                                                                                                                                    | Vysvětlení                                                                               |
|---------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------|
| Exponenciální trend | <pre> import numpy as np import statsmodels.formula.api     as smf df['log_y'] = np.log(df['y']) df['t'] = np.arange(1, len(df) +     1) m = smf.ols('log_y ~ t', data=df     ).fit() b0 = np.exp(m.params['Intercept     ']) b1 = np.exp(m.params['t']) # Predikce y_pred = np.exp(m.predict(df_new     )) </pre> | Linearizace přes <code>log_y</code> ; zpětná transformace pomocí <code>np.exp()</code> . |

## 8 Indexní analýza

Indexní analýza srovnává hodnoty ekonomických veličin (ceny, množství, výdaje) mezi dvěma obdobími: **základním** (index 0) a **běžným** (index 1).

Základní vztahy:  $Q = p \cdot q$  (výdaj = cena  $\times$  množství),  $IQ = Ip \cdot Iq$

$$Ip = \frac{p_1}{p_0}, \quad \Delta p = p_1 - p_0, \quad Iq = \frac{q_1}{q_0}, \quad \Delta q = q_1 - q_0, \quad IQ = \frac{Q_1}{Q_0}, \quad \Delta Q = Q_1 - Q_0$$

### 8.1 Složené individuální indexy

Agregují individuální změny přes všechny druhy zboží.

$$I(\Sigma q) = \frac{\sum q_1}{\sum q_0} = \frac{\sum Iq \cdot q_0}{\sum q_0} = \frac{\sum q_1}{\sum \frac{q_1}{Iq}}, \quad \Delta(\Sigma q) = \sum q_1 - \sum q_0$$

$$I(\Sigma Q) = \frac{\sum Q_1}{\sum Q_0} = \frac{\sum p_1 q_1}{\sum p_0 q_0} = \frac{\sum IQ \cdot Q_0}{\sum Q_0} = \frac{\sum Q_1}{\sum \frac{Q_1}{IQ}}, \quad \Delta(\Sigma Q) = \sum Q_1 - \sum Q_0$$

$$I\bar{p} = \frac{\bar{p}_1}{\bar{p}_0} = \frac{\frac{\sum Q_1}{\sum q_1}}{\frac{\sum Q_0}{\sum q_0}} = \frac{\sum p_1 q_1}{\sum p_0 q_0}, \quad \Delta\bar{p} = \bar{p}_1 - \bar{p}_0 = \frac{\sum p_1 q_1}{\sum q_1} - \frac{\sum p_0 q_0}{\sum q_0}$$

kde  $\bar{p}$  je vážený průměr cen (**weighted.mean**), kde váhy jsou množství  $q$ : v období 0 jsou váhy  $q_0$ , v období 1 jsou váhy  $q_1$ .

#### Implementace v R

| Funkce                  | Příklad použití                                                                                                                                         | Vysvětlení                                                           |
|-------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------|
| Individuální indexy     | <pre>Ip &lt;- p1 / p0 Iq &lt;- q1 / q0 IQ &lt;- (p1 * q1) / (p0 * q0)</pre>                                                                             | Individuální cenový, množství a výdajový index pro každé zboží.      |
| Složené individ. indexy | <pre>I_sum_q &lt;- sum(q1) / sum(q0) I_sum_Q &lt;- sum(p1*q1) / sum(p0*q0) I_p_bar &lt;- weighted.mean(p1, q1) /            weighted.mean(p0, q0)</pre> | Složené individuální indexy součtů množství, výdajů a průměrné ceny. |

#### Implementace v Python



| Funkce                  | Příklad použití                                                                                                                                      | Vysvětlení                                                           |
|-------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------|
| Individuální indexy     | <pre>Ip = p1 / p0 Iq = q1 / q0 IQ = (p1 * q1) / (p0 * q0)</pre>                                                                                      | Individuální cenový, množství a výdajový index pro každé zboží.      |
| Složené individ. indexy | <pre>I_sum_q = q1.sum() / q0.sum() I_sum_Q = (p1*q1).sum() / (p0*q0).sum() I_p_bar = (np.average(p1, weights=q1) / np.average(p0, weights=q0))</pre> | Složené individuální indexy součtů množství, výdajů a průměrné ceny. |

## 8.2 Souhrnné (Laspeyresovy a Paascheho) indexy

Souhrnné indexy fixují váhy buď v základním období (**Laspeyresovy**, superindex  $L$ ), nebo v běžném období (**Paascheho**, superindex  $P$ ).

**Souhrnné cenové indexy:**

$$I_p^{(L)} = \frac{\sum p_1 q_0}{\sum p_0 q_0} = \frac{\sum I_p \cdot p_0 q_0}{\sum p_0 q_0} = \frac{\sum I_p \cdot Q_0}{\sum Q_0} \quad I_p^{(P)} = \frac{\sum p_1 q_1}{\sum p_0 q_1} = \frac{\sum p_1 q_1}{\sum \frac{p_1 q_1}{I_p}} = \frac{\sum Q_1}{\sum \frac{Q_1}{I_p}}$$

**Souhrnné množství indexy:**

$$I_q^{(L)} = \frac{\sum p_0 q_1}{\sum p_0 q_0} = \frac{\sum I_q \cdot p_0 q_0}{\sum p_0 q_0} = \frac{\sum I_q \cdot Q_0}{\sum Q_0} \quad I_q^{(P)} = \frac{\sum p_1 q_1}{\sum p_1 q_0} = \frac{\sum p_1 q_1}{\sum \frac{p_1 q_1}{I_q}} = \frac{\sum Q_1}{\sum \frac{Q_1}{I_q}}$$

kde  $p_0, p_1$  jsou ceny v základním a běžném období,  $q_0, q_1$  jsou množství,  $Q_0 = p_0 q_0$ ,  $Q_1 = p_1 q_1$  jsou výdaje.

### Implementace v R

| Funkce              | Příklad použití                                                                        | Vysvětlení                                             |
|---------------------|----------------------------------------------------------------------------------------|--------------------------------------------------------|
| Laspeyresovy indexy | <pre>IpL &lt;- sum(p1 * q0) / sum(p0 * q0) IqL &lt;- sum(p0 * q1) / sum(p0 * q0)</pre> | Laspeyresův cenový a množství index (váhy z období 0). |
| Paascheho indexy    | <pre>IpP &lt;- sum(p1 * q1) / sum(p0 * q1) IqP &lt;- sum(p1 * q1) / sum(p1 * q0)</pre> | Paascheho cenový a množství index (váhy z období 1).   |

## Implementace v Python

| Funkce              | Příklad použití                                                                            | Vysvětlení                                               |
|---------------------|--------------------------------------------------------------------------------------------|----------------------------------------------------------|
| Laspeyresovy indexy | <pre>IpL = (p1 * q0).sum() / (p0 * q0).sum() IqL = (p0 * q1).sum() / (p0 * q0).sum()</pre> | Laspeyresův cenový a množstevní index (váhy z období 0). |
| Paascheho indexy    | <pre>IpP = (p1 * q1).sum() / (p0 * q1).sum() IqP = (p1 * q1).sum() / (p1 * q0).sum()</pre> | Paascheho cenový a množstevní index (váhy z období 1).   |

## 8.3 Fisherův (ideální) index

Fisherův index je geometrický průměr Laspeyresova a Paascheho indexu. Platí  $I_p^{(F)} \cdot I_q^{(F)} = I(\Sigma Q)$  (faktorový rozklad).

$$I_p^{(F)} = \sqrt{I_p^{(L)} \cdot I_p^{(P)}}, \quad I_q^{(F)} = \sqrt{I_q^{(L)} \cdot I_q^{(P)}}$$

## Implementace v R

| Funkce         | Příklad použití                                                | Vysvětlení                                          |
|----------------|----------------------------------------------------------------|-----------------------------------------------------|
| Fisherův index | <pre>IpF &lt;- sqrt(IpL * IpP) IqF &lt;- sqrt(IqL * IqP)</pre> | Geometrický průměr Laspeyresova a Paascheho indexu. |

## Implementace v Python

| Funkce         | Příklad použití                                              | Vysvětlení                                          |
|----------------|--------------------------------------------------------------|-----------------------------------------------------|
| Fisherův index | <pre>IpF = np.sqrt(IpL * IpP) IqF = np.sqrt(IqL * IqP)</pre> | Geometrický průměr Laspeyresova a Paascheho indexu. |

## 9 Příloha: Utility funkce v Pythonu

### 9.1 Užitečné knihovny a základy

| Funkce                                       | Příklad použití                       | Vysvětlení                                    |
|----------------------------------------------|---------------------------------------|-----------------------------------------------|
| <code>import numpy as np</code>              | <code>np.array([...])</code>          | Matice, vektory a rychlé matematické operace. |
| <code>import pandas as pd</code>             | <code>pd.DataFrame(matice)</code>     | Analýza tabulek a práce s CSV.                |
| <code>import matplotlib.pyplot as plt</code> | <code>plt.hist(data)</code>           | Tvorba grafů a vizualizace dat.               |
| <code>math.comb(n, k)</code>                 | <code>math.comb(10, 3)</code>         | Kombinační číslo (výběr $k$ z $n$ ).          |
| List Comprehension                           | <code>[x**2 for x in range(5)]</code> | Dynamické generování pole pomocí cyklu.       |

### 9.2 Práce s poli (Standardní Python)

| Funkce                                         | Příklad použití                       | Vysvětlení                                                                  |
|------------------------------------------------|---------------------------------------|-----------------------------------------------------------------------------|
| List Comprehension                             | <code>[x**2 for x in range(5)]</code> | Dynamické generování pole pomocí cyklu.                                     |
| <code>x[start:stop:krok]</code>                | <code>pole[1:10:2]</code>             | Výřez (stop je exkluzivní). <code>[::-1]</code> pro otočení.                |
| <code>x.copy()</code> vs <code>deepcopy</code> | <code>a = b.copy()</code>             | <code>copy</code> je plytká, <code>deepcopy</code> kopíruje i vnořená pole. |
| <code>x.append(v)</code>                       | <code>data.append(10)</code>          | Přidání jednoho prvku na konec pole.                                        |
| <code>x.extend(a)</code>                       | <code>data.extend([1,2,3])</code>     | Přidání více prvků na konec pole.                                           |

### 9.3 Základní Python (Built-in & Math)

| Funkce                          | Příklad použití                   | Vysvětlení                                           |
|---------------------------------|-----------------------------------|------------------------------------------------------|
| <code>help(funkce)</code>       | <code>help(print)</code>          | Dokumentace pro zadanou funkci.                      |
| <code>range(start, stop)</code> | <code>list(range(0, 5))</code>    | Vygeneruje sekvenci [0, 1, 2, 3, 4].                 |
| <code>math.log(x, b)</code>     | <code>math.log(8, 2)</code>       | Logaritmus čísla $x$ o základu $b$ .                 |
| <code>math.sqrt(x)</code>       | <code>math.sqrt(16)</code>        | Druhá odmocnina čísla.                               |
| <code>math.ceil / floor</code>  | <code>math.ceil(2.1)</code>       | Zaokrouhlení nahoru (3) / dolů (2).                  |
| <code>math.trunc(x)</code>      | <code>math.trunc(2.9)</code>      | Odříznutí desetinné části (2).                       |
| <code>math.comb(n, k)</code>    | <code>math.comb(10, 3)</code>     | Kombinační číslo (počet kombinací $k$ prvků z $n$ ). |
| <code>def function(...):</code> | <code>def funkce(x, y, z):</code> | Definice vlastní funkce s parametry.                 |

## 9.4 Statistika a Matice (Knihovna NumPy a jiné)

| Funkce                                | Příklad použití                                      | Vysvětlení                                                                      |
|---------------------------------------|------------------------------------------------------|---------------------------------------------------------------------------------|
| <code>np.sum(x)</code>                | <code>np.sum(data, axis=0)</code>                    | Součet všech prvků v poli (nebo podél zvolené osy).                             |
| <code>np.mean(x)</code>               | <code>np.mean(data)</code>                           | Průměr všech prvků v poli.                                                      |
| <code>np.prod(x)</code>               | <code>np.prod(data)</code>                           | Součin všech prvků v poli.                                                      |
| <code>np.sqrt(x)</code>               | <code>np.sqrt(data)</code>                           | Druhá odmocnina z každého prvku v poli.                                         |
| <code>np.random.rand(n)</code>        | <code>np.random.rand(100)</code>                     | Generování pole $n$ náhodných čísel z rovnoměrného rozdělení na $[0, 1)$ .      |
| <code>np.random.uniform(a,b,n)</code> | <code>np.random.uniform(10, 50, 100)</code>          | Generuje $n$ náhodných <b>desetinných</b> čísel v rozsahu $[a, b)$ .            |
| <code>np.quantile(x, q)</code>        | <code>np.quantile(x, 0.75, method='midpoint')</code> | Výpočet kvantilu ( $q \in [0, 1]$ ).                                            |
| Modus                                 | <code>statistics.multimode(data)</code>              | Vrací modus z pole (i více prvků)                                               |
| <code>np.log10(x)</code>              | <code>np.log10(data)</code>                          | Dekadický logaritmus (základ 10). Často se používá pro normalizaci dat.         |
| <code>np.linalg.norm(x, p)</code>     | <code>np.linalg.norm(x, ord=2)</code>                | Výpočet $L^1, L^2$ nebo $L^\infty$ ( <code>np.inf</code> ) normy.               |
| <code>np.insert / np.delete</code>    | <code>np.insert(A, 1, [...], axis=0)</code>          | Vloží/Smaže řádek ( <code>axis=0</code> ) nebo sloupec ( <code>axis=1</code> ). |

| Funkce                            | Příklad použití                                    | Vysvětlení                                                                                                               |
|-----------------------------------|----------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------|
| <code>stats.gmean(x)</code>       | <code>stats.gmean(x)</code>                        | Geometrický průměr (knihovna Scipy).                                                                                     |
| <code>stats.hmean(x)</code>       | <code>stats.hmean(x, weights=[...])</code>         | Harmonický průměr (knihovna Scipy).                                                                                      |
| <code>np.var(x, ddof=0)</code>    | <code>np.var(data, ddof=0)</code>                  | <b>Klasický rozptyl</b> $s_x^2$ (děleno $n$ ).                                                                           |
| <code>np.var(x, ddof=1)</code>    | <code>np.var(data, ddof=1)</code>                  | <b>Výběrový rozptyl</b> $S^2$ (děleno $n - 1$ ).                                                                         |
| <code>np.std(x, ddof=0)</code>    | <code>np.std(data, ddof=0)</code>                  | Klasická směrodatná odchylka $s_x$ .                                                                                     |
| <code>np.std(x, ddof=1)</code>    | <code>np.std(data, ddof=1)</code>                  | Výběrová směrodatná odchylka $S$ .                                                                                       |
| <code>v_x = std / mean</code>     | <code>np.std(x, ddof=1) / np.mean(x)</code>        | <b>Variační koeficient</b> $v_x$ (relativní variabilita).                                                                |
| <code>np.where(cond, x, y)</code> | <code>np.where(df['am'] == 0, 'aut', 'man')</code> | <b>Podmíněný sloupec:</b> Pokud platí <code>cond</code> , vlož <code>x</code> , jinak <code>y</code> (jako IF v Excelu). |

## 9.5 Pandas: Analýza dat

| Funkce                                      | Příklad použití                                                                          | Vysvětlení                                                                                                            |
|---------------------------------------------|------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------|
| <code>pd.to_datetime()</code>               | <pre>df['datum'] = pd.to_datetime(df['datum']) df.set_index('datum', inplace=True)</pre> | Převod textového sloupce na datumové hodnoty a jeho následné nastavení jako indexu tabulky (klíčové pro časové řady). |
| <code>pd.date_range()</code>                | <pre>pd.date_range(start='2020-01-01', periods=10, freq='Q')</pre>                       | Vygeneruje časovou osu, zde například se čtvrtletní ('Q') frekvencí.                                                  |
| <code>pd.read_csv(file)</code>              | <pre>pd.read_csv('data.csv')</pre>                                                       | Načte data z CSV souboru a vytvoří DataFrame.                                                                         |
| <code>df.describe()</code>                  | <pre>df.describe()</pre>                                                                 | Souhrnné statistiky (průměr, std, kvartily, atd.).                                                                    |
| <code>df[columns]</code>                    | <pre>df[["A", "B", "C"]]</pre>                                                           | Výběr určitých sloupců.                                                                                               |
| Filtrování                                  | <pre>df[df['Věk'] &gt;= 18]</pre>                                                        | Vybere pouze řádky splňující danou podmínku.                                                                          |
| <code>df['A'].isin([list])</code>           | <pre>df[df['mesto'].isin(['Praha', 'Brno'])]</pre>                                       | Vybere řádky, kde hodnota sloupce odpovídá prvkům v seznamu.                                                          |
| <code>df.loc</code><br><code>df.iloc</code> | vs<br><pre>df.loc[0, 'Sloupec']</pre>                                                    | Výběr dat podle <b>názvů</b> (loc) vs. <b>pozice</b> (iloc).                                                          |

| Funkce                             | Příklad použití                                   | Vysvětlení                                                                             |
|------------------------------------|---------------------------------------------------|----------------------------------------------------------------------------------------|
| <code>df.isna().sum()</code>       | <code>df.isna().sum()</code>                      | Počet chybějících (null) hodnot v tabulce.                                             |
| <code>df.value_counts()</code>     | <code>df['A'].value_counts()</code>               | Tabulka četností pro kategorická data.                                                 |
| <code>df.groupby('A')</code>       | <code>df.groupby('A').mean()</code>               | Výpočet statistik podle kategorií ve sloupci 'A'.                                      |
| <code>df.cumsum()</code>           | <code>df['cetnost'].cumsum()</code>               | <b>Kumulativní součet:</b> Pro výpočet kumulativních absolutních/relativních četností. |
| <code>pd.crosstab()</code>         | <code>pd.crosstab(df['A'], df['B'])</code>        | Kontingenční tabulka četností dvou kategorií.                                          |
| <code>pd.pivot_table()</code>      | <code>df.pivot_table(values='C', \dots)</code>    | Univerzální pivotní tabulka.                                                           |
| <code>df['A'].between(a, b)</code> | <code>df[df['mzda'].between(30000, 50000)]</code> | Filtrování hodnot v uzavřeném intervalu [a, b].                                        |



## 9.6 Matplotlib a Seaborn: Vizualizace

| Funkce                               | Příklad použití                                                              | Vysvětlení                                                                                                           |
|--------------------------------------|------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------|
| <code>df.boxplot()</code>            | <pre>df.boxplot(column='Y', by='X')</pre>                                    | <b>Boxplot (Pandas):</b> Rozdělení dat do kvartilů dle skupiny.                                                      |
| <code>plt.hist(x)</code>             | <pre>plt.hist(data, bins=15)</pre>                                           | <b>Histogram:</b> Rozdělení četností. <code>bins</code> určuje intervaly.                                            |
| <code>plt.scatter(x, y)</code>       | <pre>plt.scatter(x, y, alpha=0.5)</pre>                                      | <b>Bodový graf:</b> Závislost dvou proměnných.                                                                       |
| <code>plt.title(s)</code>            | <pre>plt.title("Název",<br/>fontsize=16)</pre>                               | Nastaví hlavní nadpis grafu.                                                                                         |
| <code>plt.xlabel /<br/>ylabel</code> | <pre>plt.xlabel("Čas [s]")</pre>                                             | Nastaví popisky os <i>x</i> a <i>y</i> .                                                                             |
| <code>plt.legend()</code>            | <pre>plt.legend(loc='upper right')</pre>                                     | Zobrazí legendu (nutný parametr <code>label</code> u dat).                                                           |
| <code>plt.savefig()</code>           | <pre>plt.savefig("graf.pdf")</pre>                                           | Uloží graf na disk.                                                                                                  |
| <code>sns.regplot()</code>           | <pre>import seaborn as sns<br/>sns.regplot(data=df, x='TV', y='Sales')</pre> | Vykreslí bodový graf ( <code>scatter</code> ) a rovnou jím proloží regresní přímku (včetně intervalu spolehlivosti). |

## 10 Příloha: Utility funkce v R

### 10.1 Užitečné balíčky

| Funkce                        | Příklad použití               | Vysvětlení                                                                                                                             |
|-------------------------------|-------------------------------|----------------------------------------------------------------------------------------------------------------------------------------|
| <code>library(stats)</code>   | <code>library(stats)</code>   | Základní statistické funkce (součást R) — <code>t.test</code> , <code>chisq.test</code> , <code>aov</code> , <code>lm</code> , ...     |
| <code>library(ggplot2)</code> | <code>library(ggplot2)</code> | Vizualizace dat (grafy).                                                                                                               |
| <code>library(dplyr)</code>   | <code>library(dplyr)</code>   | Manipulace s daty — <code>filter</code> , <code>select</code> , <code>mutate</code> , <code>group_by</code> , <code>summarise</code> . |
| <code>library(readr)</code>   | <code>library(readr)</code>   | Načítání CSV a textových souborů.                                                                                                      |

### 10.2 Vektory a datové typy

#### Datové typy a konverze

| Funkce                                                        | Příklad použití                                                                                                                                          | Vysvětlení                          |
|---------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------|
| <code>class(x)</code>                                         | <code>class(3.14) # "numeric"</code><br><code>class(TRUE) # "logical"</code><br><code>class("ahoj") # "character"</code>                                 | Vrátí datový typ objektu.           |
| <code>is.numeric /</code><br><code>is.character</code><br>... | <code>is.numeric(3.14) # TRUE</code><br><code>is.integer(3L) # TRUE</code><br><code>is.logical(FALSE) # TRUE</code>                                      | Ověří datový typ; vrací TRUE/FALSE. |
| <code>as.numeric(x)</code>                                    | <code>as.numeric("3.14") # 3.14</code><br><code>as.integer(3.7) # 3</code><br><code>as.character(42) # "42"</code><br><code>as.logical(0) # FALSE</code> | Konverze na jiný typ.               |
| <code>is.na(x)</code>                                         | <code>is.na(NA) # TRUE</code><br><code>is.na(NaN) # TRUE</code><br><code>is.na(Inf) # FALSE</code><br><code>colSums(is.na(df)) # NA po sl.</code>        | Detekce chybějící hodnoty (NA/NaN). |

#### Vektory

| Funkce                          | Příklad použití                                                                                     | Vysvětlení                         |
|---------------------------------|-----------------------------------------------------------------------------------------------------|------------------------------------|
| <code>c(...)</code>             | <pre>c(1, 2, 3) c("a", "b") c(x, y) # spojení vektorů</pre>                                         | Vytvoří vektor nebo spojí vektory. |
| <code>seq(from, to, by)</code>  | <pre>1:10 seq(2, 10, by = 2) # 2,4,6,8,10</pre>                                                     | Vytvoří sekvenci čísel.            |
| <code>x[i]</code>               | <pre>x[1] # první prvek x[1:3] # prvky 1-3 x[-2] # vše kromě 2. x[x &gt; 5] # podmíněný výběr</pre> | Indexování vektoru.                |
| <code>length(x) / rev(x)</code> | <pre>length(c(1,2,3)) # 3 rev(c(1,2,3)) # 3 2 1</pre>                                               | Délka vektoru a obrácení pořadí.   |
| <code>names(x)</code>           | <pre>names(x) &lt;- c("a","b","c") x["a"] # výběr dle jména</pre>                                   | Pojmenování prvků vektoru.         |

## 10.3 Práce s daty v R

### Data frames

| Funkce                                                 | Příklad použití                                                                                                                         | Vysvětlení                              |
|--------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------|
| <code>str(df)</code> /<br><code>summary(df)</code>     | <pre>str(mtcars) summary(mtcars) dim(mtcars) # c(32, 11)</pre>                                                                          | Struktura, přehled a rozměry tabulky.   |
| <code>head(df, n)</code> /<br><code>tail(df, n)</code> | <pre>head(mtcars) # prvních 6 head(mtcars, 10) # prvních 10 tail(mtcars) # posledních 6</pre>                                           | Náhled na prvních / posledních n řádků. |
| <code>df[r, c]</code> /<br><code>df\$col</code>        | <pre>df[2, 3] # jeden prvek df[1, ] # 1. řádek df[, 2] # 2. sloupec df\$mpg # sloupec mpg df[df\$mpg &gt; 20, ] # podmíněný výběr</pre> | Indexování data.frameu.                 |
| <code>colSums()</code> /<br><code>colMeans()</code>    | <pre>colSums(df) colMeans(df, na.rm = TRUE) apply(df, 2, mean, na.rm = TRUE)</pre>                                                      | Součet / průměr každého sloupce.        |
| <code>cbind()</code> / <code>rbind()</code>            | <pre>cbind(df, novy = c(...)) #     sloupec rbind(df, c(...)) # řádek df[-1, ] # odebrání 1. řádku df[, -2] # odebrání 2. sloupce</pre> | Přidání nebo odebrání řádků / sloupců.  |

## Import a export dat

| Funkce                                         | Příklad použití                                                                        | Vysvětlení                             |
|------------------------------------------------|----------------------------------------------------------------------------------------|----------------------------------------|
| <code>read.table()</code>                      | <pre>read.table("data.csv",     sep = ";", header = TRUE)</pre>                        | Načte textový soubor do data.frameu.   |
| <code>read.csv()</code>                        | <pre>read.csv("data.csv") read.csv("data.csv", sep = ",")</pre>                        | Zkratka pro CSV soubory.               |
| <code>write.table()</code>                     | <pre>write.table(mtcars,     file = "out.csv", sep = ";",     row.names = FALSE)</pre> | Uloží data.frame do textového souboru. |
| <code>getwd()</code> /<br><code>setwd()</code> | <pre>getwd() setwd("C:/Users/.../data")</pre>                                          | Zjistí nebo nastaví pracovní složku.   |

## Četnosti a diskretizace

| Funkce                      | Příklad použití                                                               | Vysvětlení                                    |
|-----------------------------|-------------------------------------------------------------------------------|-----------------------------------------------|
| <code>table(x)</code>       | <pre>ni &lt;- table(data\$kraj) pi &lt;- prop.table(ni)</pre>                 | Absolutní a relativní četnosti.               |
| <code>cumsum(x)</code>      | <pre>Ni &lt;- cumsum(ni) Pi &lt;- cumsum(pi)</pre>                            | Kumulativní (absolutní / relativní) četnosti. |
| <code>cut(x, breaks)</code> | <pre>cut(x,     breaks = seq(0, 20, by = 2),     include.lowest = TRUE)</pre> | Diskretizuje spojitou proměnnou do intervalů. |

**Balíček dplyr** (`|>` = roura: výsledek vlevo jde jako 1. argument vpravo)

| Funkce                   | Příklad použití                                                                                        | Vysvětlení                                                      |
|--------------------------|--------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------|
| <code>filter()</code>    | <pre>mtcars  &gt; filter(mpg &gt; 20) mtcars  &gt; filter(mpg &gt; 20,                 cyl == 6)</pre> | Výběr řádků splňujících podmínku.                               |
| <code>select()</code>    | <pre>mtcars  &gt; select(mpg, cyl, hp)</pre>                                                           | Výběr (podmnožiny) sloupců.                                     |
| <code>mutate()</code>    | <pre>mtcars  &gt; mutate(     pwr_wt = hp / wt)</pre>                                                  | Přidá nový sloupec odvozený od existujících.                    |
| <code>summarise()</code> | <pre>mtcars  &gt; summarise(     prumer = mean(mpg),     odch = sd(mpg))</pre>                         | Souhrnné statistiky (redukuje tabulku na 1 řádek).              |
| <code>group_by()</code>  | <pre>mtcars  &gt;   group_by(cyl)  &gt;   summarise(n = n(),             prumer = mean(mpg))</pre>     | Seskupení řádků; <b>summarise</b> pak počítá za každou skupinu. |
| <code>count()</code>     | <pre>mtcars  &gt; count(cyl) data  &gt; count(kraj)  &gt;   arrange(desc(n))</pre>                     | Absolutní četnosti pro každou hodnotu.                          |
| <code>arrange()</code>   | <pre>mtcars  &gt; arrange(mpg) mtcars  &gt; arrange(desc(mpg))</pre>                                   | Seřadí řádky vzestupně / sestupně.                              |
| <code>pull()</code>      | <pre>mtcars  &gt;   filter(cyl==6)  &gt; pull(mpg)</pre>                                               | Extrahuje sloupec jako prostý vektor.                           |